

Universidade de Brasília – UnB
Faculdade de Ciências e Tecnologias em Engenharia – FCTE
Engenharia de Software

Avaliação de modelos de visão computacional na identificação de padrões associados à hanseníase em imagens

Autor: Euller Júlio da Silva, Gabriel Henrique Castelo Costa
Orientador: Hilmer Rodrigues Neri

Brasília, DF
2026



Folha de rosto

Euller Júlio da Silva, Gabriel Henrique Castelo Costa

Avaliação de modelos de visão computacional na identificação de padrões associados à hanseníase em imagens

Monografia submetida ao curso de graduação em Engenharia de Software da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia de Software.

Universidade de Brasília – UnB

Faculdade de Ciências e Tecnologias em Engenharia – FCTE

Orientador: Hilmer Rodrigues Neri

Coorientador: Vinicius de Carvalho Rispoli

Brasília, DF

2026

Sumário

1 INTRODUÇÃO 4
1.1 Contexto 4
1.2 Problema 5
1.3 Questão de pesquisa 6
1.3.1 GQM adaptado 6
1.3.2 Questão norteadora 7
1.4 Objetivos 7
1.4.1 Objetivo geral 7
1.4.2 Objetivos específicos 8
1.5 Metodologia 8
1.6 Organização do trabalho 8
1.7 Cronograma e fluxo de atividades 9
1.7.1 Atividades da primeira etapa 9
1.7.2 Atividades da segunda etapa 9

2 REFERENCIAL TEÓRICO 10
2.1 Experimentação na engenharia de software 10
2.1.1 Experimento 10
2.1.1.1 Definição do escopo 11
2.1.1.2 Planejamento 11
2.1.1.3 Operação 11
2.1.1.4 Análise e interpretação 12
2.1.1.5 Apresentação e documentação 12
2.1.2 Revisão sistemática da literatura 12
2.2 Hanseníase e identificação de manifestações cutâneas 12
2.3 Inteligência artificial e visão computacional 13
2.3.1 Aprendizado de máquina e aprendizado profundo 13
2.3.2 Tarefas de análise de imagens 13
2.4 Métricas e dimensões de avaliação 13
2.4.1 Resultados de classificação 13
2.4.2 Métricas relacionadas à questão de pesquisa 14
2.5 Avaliação e generalização dos modelos 18

3 REVISÃO ESTRUTURADA DA LITERATURA 19
3.1 Planejamento e protocolo 19
3.2 Estruturação da estratégia de busca 20

3.2.1 Definição dos componentes PICOC e string de busca 20
3.2.2 Prompt estruturado submetido à plataforma Consensus 22
3.2.3 Consultas apresentadas pelo Consensus 24
3.3 Realização da busca e seleção dos artigos 25
3.3.1 Busca e identificação dos registros 25
3.3.2 Critérios de seleção 25
3.3.3 Triagem e seleção para leitura integral 27
3.3.4 Extração e síntese das evidências 29
3.4 Resultados da revisão 30
3.4.1 Quais técnicas de visão computacional são utilizadas? 30
3.4.2 Quais conjuntos de dados e populações são utilizados? 31
3.4.3 Quais métodos e procedimentos de avaliação são empregados? 32
3.4.4 Quais métricas e resultados são reportados? 32
3.4.5 Como o desempenho varia entre grupos ou tons de pele? 34
3.4.6 Quais modelos e abordagens de inteligência artificial são empregados? 34
3.4.7 Como a generalização dos modelos é avaliada? 36
3.4.8 Em quais veículos os estudos são publicados? 37

REFERÊNCIAS 40

APÊNDICES 43

APÊNDICE A – NOTAS PARA REVISÃO COM OS ORIENTADORES — FORA DO TEXTO DO CAPÍTULO . 44
A.1 Estrutura adotada e relação com os exemplos 44
A.2 Pontos que precisam de decisão 44
A.3 Mapa das afirmações e das fontes 45
A.4 Situação do repositório consultado 45

1 Introdução

Este capítulo apresenta o contexto da aplicação de modelos de visão computacional à identificação de manifestações dermatológicas associadas à hanseníase. São delimitados o problema de pesquisa, a questão norteadora e os objetivos do trabalho, considerando a avaliação de desempenho na identificação de padrões associados à hanseníase em imagens de pele, no contexto de apoio à triagem na rede pública de saúde do Brasil.

1.1 Contexto

A hanseníase integra o grupo das doenças tropicais negligenciadas e constitui um desafio para a identificação oportuna de casos e o acompanhamento das pessoas afetadas. Em sua revisão da literatura, Fernandes et al. (2024) destacam que o diagnóstico se baseia principalmente na avaliação clínica e que a semelhança com outras condições dermatológicas pode dificultar o reconhecimento da doença. Nesse contexto, a investigação de recursos computacionais de apoio à análise de manifestações cutâneas pode contribuir para ampliar as possibilidades de suporte aos profissionais de saúde, desde que sua avaliação considere as características da tarefa e da população de interesse.

A análise automatizada de imagens dermatológicas tem sido investigada por meio de técnicas de aprendizado de máquina e aprendizado profundo. Fernandes et al. (2024) identificaram 21 estudos sobre inteligência artificial no apoio ao diagnóstico da hanseníase e observaram que a maior parte utilizava imagens de lesões cutâneas e tarefas de classificação multiclasse. A inclusão da hanseníase em sistemas voltados a diferentes doenças indica que os resultados dessas propostas devem ser interpretados tanto em relação ao conjunto de classes quanto ao reconhecimento específico da doença.

Entre os estudos experimentais, Jaikishore, Udutalapally e Das (2021) desenvolveram uma abordagem baseada em MobileNetV2 para classificar imagens de eczema, sarampo, hanseníase e pele saudável, incorporando o modelo a um protótipo Android. Yotsu et al. (2023), por sua vez, avaliaram ResNet-50 e VGG-16 na classificação de cinco doenças tropicais negligenciadas com manifestações cutâneas. Em outra linha de investigação, Eita e Rizk (2025) propuseram um sistema baseado em YOLOv8 para localizar e classificar lesões de diferentes condições, incluindo hanseníase, com uso de mapas de saliência para apoiar a interpretação das predições. Esses trabalhos ilustram abordagens distintas de análise de imagens, com diferentes requisitos de dados, saídas e procedimentos de avaliação.

O campo também compreende tarefas relacionadas ao acompanhamento de mani-

festações e complicações da doença. Sanchez et al. (2024) apresentaram o CO2Wounds-V2, um conjunto de fotografias de feridas crônicas de pacientes com hanseníase, acompanhado de experimentos de segmentação semântica. Nesse caso, a tarefa consiste em delimitar regiões de ferida nas imagens, e não em determinar se o paciente apresenta hanseníase. Essa distinção é necessária para organizar a literatura e evitar que medidas de segmentação sejam interpretadas como evidências de desempenho diagnóstico.

A caracterização das populações representadas nos dados também integra a avaliação dos modelos. Yotsu et al. (2023) utilizaram fotografias coletadas em Costa do Marfim e Gana, descrevendo a população como composta por pessoas de pele escura, com fototipos de Fitzpatrick IV ou superiores. O estudo oferece evidências diretamente relacionadas à análise de imagens de pele escura, mas não apresenta comparação de desempenho entre os diferentes fototipos. Eita e Rizk (2025) também reconhecem limitações na diversidade dos dados e apontam a ampliação da representação de pessoas com tons de pele mais escuros como uma direção de trabalho futuro.

Esses estudos motivam a investigação de como o desempenho dos modelos é definido, mensurado e interpretado. Para o presente trabalho, a avaliação compreende os resultados preditivos relativos à tarefa, os procedimentos empregados para obtê-los e as evidências disponíveis sobre sua aplicação a novos dados e a diferentes grupos de tom de pele. A utilização futura em apoio à triagem na rede pública de saúde do Brasil constitui o contexto de interesse da pesquisa, sem que os resultados computacionais sejam, por si só, considerados demonstração de efetividade clínica.

1.2 Problema

A existência de modelos capazes de reconhecer padrões em imagens não estabelece, isoladamente, sua adequação à identificação de manifestações de hanseníase em uma população específica. Os estudos analisados apresentam diferenças nas tarefas, nas classes de interesse, na composição dos conjuntos de dados e nas métricas utilizadas. Classificar uma imagem entre doenças, localizar uma lesão e segmentar uma ferida produzem resultados com significados distintos. Consequentemente, uma comparação baseada apenas nos maiores valores publicados pode desconsiderar diferenças essenciais entre os experimentos (YOTSU et al., 2023; SANCHEZ et al., 2024; EITA; RIZK, 2025).

Além disso, medidas agregadas podem não representar adequadamente o desempenho referente à hanseníase. No estudo de Yotsu et al. (2023), a Task 2 apresentou acurácias globais de 77% e 80% nos dois cenários avaliados. Entretanto, a leitura da diagonal correspondente à hanseníase nas matrizes de confusão indica proporções de classificação correta de 12% e 13%, respectivamente. Como as linhas representam a classe real, esses valores podem ser interpretados como sensibilidade por imagem para a classe hanseníase. O con-

traste evidencia a importância de examinar resultados específicos por doença, em vez de atribuir à hanseníase o desempenho global do sistema.

A relação entre os resultados obtidos e os tons de pele constitui outra dimensão do problema. A presença de imagens de pele escura em um conjunto de dados não demonstra que o modelo apresente comportamento equivalente entre diferentes tons. No estudo de Yotsu et al. (2023), a população é caracterizada por um intervalo de fototipos, mas não são fornecidos resultados separados por esses grupos. Já Eita e Rizk (2025) reconhecem limitações de representatividade e a necessidade de ampliar a diversidade dos dados. Essas observações sustentam a necessidade de examinar a caracterização populacional e a avaliação por grupos, sem permitir concluir, a partir dessas evidências isoladas, que todos os modelos tenham desempenho inferior em pele negra.

Também permanece necessário distinguir a avaliação computacional da avaliação em contexto assistencial. O desenvolvimento de um aplicativo ou a obtenção de resultados em conjuntos de imagens não comprova sua contribuição para o atendimento em serviços de saúde. Enquanto Jaikishore, Udutalapally e Das (2021) apresentam um protótipo de aplicação móvel, Eita e Rizk (2025) situam os estudos prospectivos com dermatologistas entre as atividades futuras. Assim, a relevância dessas propostas para a rede pública exige considerar o alcance e os limites dos procedimentos de validação relatados.

Diante desse cenário, o problema investigado consiste em compreender quais evidências e procedimentos permitem avaliar o desempenho de modelos de visão computacional na identificação de manifestações dermatológicas associadas à hanseníase, no contexto de apoio à triagem na rede pública de saúde do Brasil, considerando a tarefa realizada, as características dos dados e os limites de generalização dos resultados. A comparação entre tons de pele será examinada quando houver informações disponíveis, como uma dimensão complementar da avaliação. A revisão em andamento buscará sistematizar essas informações e identificar os aspectos que precisam ser considerados no planejamento de avaliações futuras.

1.3 Questão de pesquisa

1.3.1 GQM adaptado

O objetivo de análise foi organizado por meio de um GQM adaptado, que explicita o objeto, o propósito, o foco, o ponto de vista e o contexto da investigação. O quadro orienta a definição da questão de pesquisa e das medidas a serem extraídas dos estudos.

Característica	Valor
Analisar	Modelos de visão computacional aplicados à identificação de manifestações dermatológicas.
Com o propósito de	Avaliar o desempenho dos modelos aplicados à identificação de padrões em imagens de pele.
Com foco em	Identificação de características patológicas de hanseníase.
Do ponto de vista de	Pesquisadores das áreas de Engenharia de Software e da área da saúde.
No contexto de	Apoio à triagem de hanseníase na rede pública de saúde do Brasil.

1.3.2 Questão norteadora

A investigação é orientada pela seguinte questão:

> Como avaliar o desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, no contexto da rede pública de saúde do Brasil?

Nesta etapa, a questão será abordada por meio da identificação e análise das evidências apresentadas na literatura. Serão examinadas as tarefas realizadas, os modelos empregados, as características dos conjuntos de dados, os procedimentos de avaliação, as métricas e os resultados, bem como as informações disponíveis sobre tons de pele e generalização. A ausência de avaliação por grupo será registrada como uma limitação das evidências disponíveis, sem ser tomada como demonstração de equidade ou de desigualdade de desempenho.

1.4 Objetivos

1.4.1 Objetivo geral

Analisar a avaliação de desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, a partir da síntese das evidências da literatura, visando fundamentar seu uso em apoio à triagem na rede pública de saúde do Brasil.

1.4.2 Objetivos específicos

1. Caracterizar as tarefas, os modelos e as abordagens de visão computacional empregados na análise de manifestações dermatológicas associadas à hanseníase.
2. Identificar os conjuntos de dados utilizados, suas formas de aquisição e anotação e as informações disponíveis sobre as populações e os tons de pele representados.
3. Sistematizar os procedimentos de avaliação, as métricas e os resultados reportados, distinguindo medidas globais, resultados específicos de hanseníase e unidades de análise.
4. Examinar as evidências de generalização e de avaliação do desempenho entre grupos de tom de pele, quando disponíveis.
5. Identificar limitações e lacunas que fundamentem o planejamento de uma avaliação futura de modelos no contexto de apoio à triagem na rede pública de saúde do Brasil.

1.5 Metodologia

Este trabalho adota uma revisão estruturada da literatura para identificar e analisar evidências sobre a avaliação de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele. A revisão compreende a definição das questões de pesquisa, da estratégia de busca, dos critérios de seleção e do formulário de extração de dados.

A condução abrange a identificação dos registros, a remoção de duplicatas, a triagem por título e resumo, a avaliação dos textos completos e a síntese das evidências dos estudos incluídos. Esses procedimentos, os critérios aplicados e o fluxo de seleção dos estudos são detalhados no Capítulo 3.

1.6 Organização do trabalho

Este trabalho está organizado em três capítulos. O primeiro apresenta o contexto, o problema de pesquisa, a questão norteadora e os objetivos. O segundo reúne os fundamentos sobre pesquisa empírica, hanseníase, visão computacional e avaliação de modelos. O terceiro descreve o planejamento, a busca e a seleção dos estudos da revisão de literatura, bem como os procedimentos previstos para a extração e a síntese das evidências. Ao final, são apresentadas as referências e os apêndices.

1.7 Cronograma e fluxo de atividades

O trabalho está organizado em etapas que compreendem o planejamento da pesquisa, a revisão da literatura e a análise das evidências obtidas. O fluxo apresentado a seguir descreve a sequência das atividades; as datas, a duração de cada etapa e eventuais atividades experimentais posteriores devem ser definidas com a orientação.

1.7.1 Atividades da primeira etapa

Na primeira etapa, foram estabelecidos o problema, a questão de pesquisa e os objetivos; estruturado o protocolo da revisão; e realizada a identificação e a triagem inicial dos estudos. Em seguida, realizou-se a leitura integral dos registros selecionados, a confirmação de sua elegibilidade, a extração das informações e a síntese dos resultados. O estado da triagem e as pendências são apresentados no Capítulo 3.

1.7.2 Atividades da segunda etapa

A continuidade do trabalho dependerá dos resultados da revisão e das definições acordadas com a orientação. Entre as atividades a planejar estão o aprofundamento da análise das evidências e a definição de procedimentos para uma avaliação futura de modelos no contexto de apoio à triagem. A realização de experimentos, a disponibilidade de dados e os prazos dessa etapa ainda precisam ser estabelecidos.

2 Referencial teórico

Neste capítulo são apresentados os conceitos que fundamentam a investigação. Inicialmente, são abordadas a pesquisa empírica em engenharia de software e a revisão sistemática da literatura. Em seguida, são apresentados aspectos da hanseníase, da aplicação de aprendizado de máquina a imagens de pele e das medidas usadas na avaliação dos modelos.

2.1 Experimentação na engenharia de software

A pesquisa empírica utiliza observações e dados para investigar fenômenos, avaliar propostas e fundamentar conclusões. Na engenharia de software, as estratégias empíricas incluem experimentos, estudos de caso e estudos secundários de literatura, cada qual com objetivos e procedimentos próprios (WOHLIN et al., 2024). A escolha entre essas estratégias depende da questão investigada e das evidências necessárias para respondê-la.

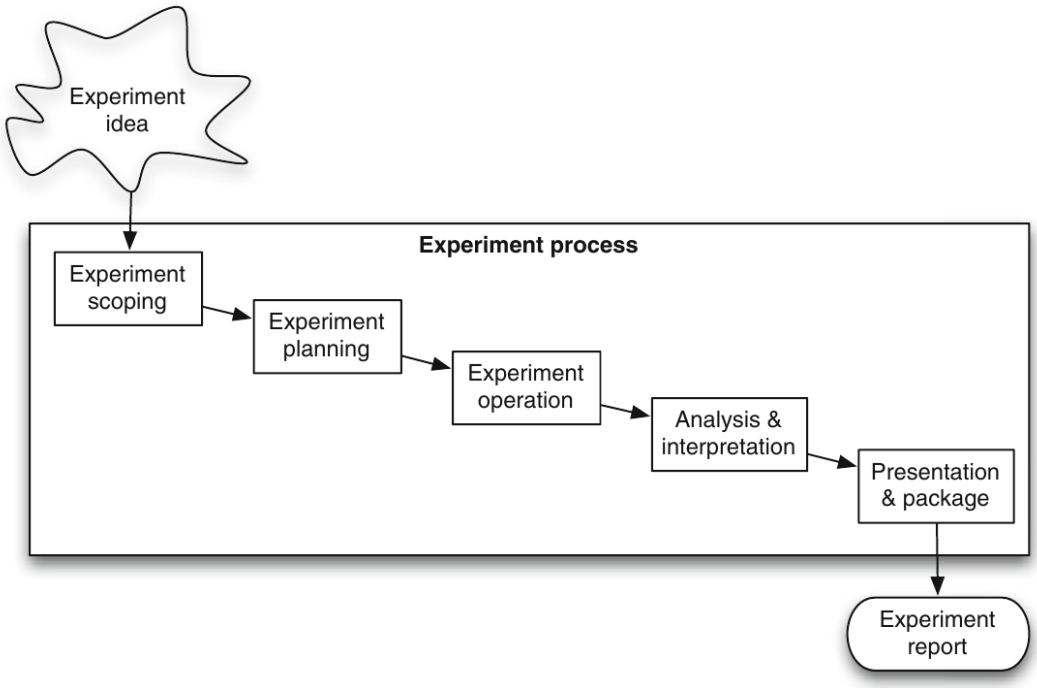
Um experimento controlado envolve a definição de fatores, tratamentos e medidas para investigar seus efeitos sob condições estabelecidas. Já uma revisão sistemática é um estudo secundário, no qual as evidências de outros trabalhos são identificadas e analisadas a partir de um processo documentado (WOHLIN et al., 2024, p. 51–56). Neste TCC, a revisão busca reunir informações sobre avaliações de modelos; sua realização não constitui, por si só, um experimento controlado ou uma validação clínica.

2.1.1 Experimento

Um experimento é empregado para investigar questões por meio de observações sob condições planejadas. Sua definição envolve, entre outros elementos, o objeto estudado, os tratamentos ou fatores considerados e as medidas usadas para observar seus efeitos. A organização do processo contribui para que as condições da investigação e os limites de interpretação sejam explicitados (WOHLIN et al., 2024, p. 79–82). Esses conceitos são apresentados como fundamentação para o trabalho e não indicam que um experimento já foi executado.

A Figura 1 apresenta uma visão geral do processo experimental proposto por Wohlin et al. (2024): definição do escopo, planejamento, operação, análise e interpretação, e apresentação e documentação. A figura ilustra o referencial metodológico; ela não representa um experimento já executado neste TCC.

Figura 1 – Visão geral do processo experimental



Fonte: Reproduzido de Wohlin et al. (2024, p. 80, Figura 6.4).

2.1.1.1 Definição do escopo

A definição do escopo delimita o objeto, o propósito, o foco de qualidade, a perspectiva e o contexto do estudo. Esses elementos orientam a pergunta que se pretende responder e as decisões das etapas seguintes. O GQM adaptado apresentado na introdução explicita esses componentes para o objetivo desta pesquisa (WOHLIN et al., 2024, p. 80).

2.1.1.2 Planejamento

No planejamento são especificados o contexto da investigação, as variáveis, as hipóteses quando aplicáveis, o desenho e os instrumentos de medição. Também são examinadas possíveis ameaças à validade. Em uma avaliação de modelos de visão computacional, essas decisões poderiam envolver a caracterização dos dados, a definição das tarefas e a escolha das métricas; o desenho efetivo de uma avaliação futura ainda depende dos resultados da revisão (WOHLIN et al., 2024, p. 80–82).

2.1.1.3 Operação

A operação corresponde à preparação e à execução do procedimento planejado, incluindo a coleta e a verificação dos dados produzidos. Seu registro permite relacionar os resultados às condições em que foram obtidos. Nesta etapa do TCC, a operação de um

experimento com modelos não foi estabelecida (WOHLIN et al., 2024).

2.1.1.4 Análise e interpretação

Após a obtenção dos dados, a análise organiza as medidas e examina os resultados em relação às questões formuladas. A interpretação deve considerar as características dos dados e as ameaças à validade, evitando estender conclusões além das condições de avaliação (WOHLIN et al., 2024).

2.1.1.5 Apresentação e documentação

O relato reúne o objetivo, o procedimento, as medidas, os resultados e as limitações, permitindo que outras pessoas compreendam e examinem o estudo. A documentação também dá suporte à comparação com investigações posteriores (WOHLIN et al., 2024).

2.1.2 Revisão sistemática da literatura

Uma revisão sistemática parte de questões de pesquisa e de um protocolo que orienta a busca, a seleção, a avaliação e a síntese dos estudos. Entre os elementos a registrar estão as fontes e estratégias de busca, os critérios de seleção e os procedimentos de extração de dados (KITCHENHAM; CHARTERS, 2007; WOHLIN et al., 2024). A descrição dessas decisões permite examinar o alcance e as limitações do conjunto de estudos identificado.

No presente trabalho, a revisão é empregada para compreender como modelos aplicados a imagens de pele relacionadas à hanseníase são avaliados. O protocolo e o andamento de sua execução são apresentados no Capítulo 3.

2.2 Hanseníase e identificação de manifestações cutâneas

A hanseníase pode apresentar manifestações na pele e comprometimento de nervos periféricos. Segundo a World Health Organization (2018), entre os sinais usados para o diagnóstico estão a perda de sensibilidade em uma mancha cutânea, alterações em nervos periféricos associadas à perda de sensibilidade e a presença de bacilos em exame de esfregaço cutâneo. Portanto, uma fotografia de pele representa somente parte das informações consideradas na avaliação clínica.

No contexto desta pesquisa, a análise computacional de imagens é tratada como possível apoio à triagem. Seu desempenho em uma base de imagens não demonstra, isoladamente, que o sistema possa estabelecer um diagnóstico ou melhorar o atendimento em um serviço de saúde. Por isso, é necessário relacionar os resultados reportados à tarefa realizada, aos dados utilizados e à forma de validação (FERNANDES et al., 2024).

2.3 Inteligência artificial e visão computacional

2.3.1 Aprendizado de máquina e aprendizado profundo

A visão computacional compreende métodos capazes de extrair e analisar informações de imagens. No aprendizado de máquina, modelos são ajustados a partir de dados para executar uma tarefa; no aprendizado profundo, redes com múltiplas camadas aprendem representações em diferentes níveis. Redes neurais convolucionais são uma das abordagens empregadas na análise de imagens (LECUN; BENGIO; HINTON, 2015).

2.3.2 Tarefas de análise de imagens

As aplicações à hanseníase diferem quanto à tarefa e ao resultado produzido. Na classificação, o modelo atribui uma categoria à imagem; na detecção, identifica e localiza objetos ou lesões; na segmentação, associa regiões ou pixels a classes de interesse. Essas saídas respondem a perguntas diferentes e devem ser avaliadas com medidas apropriadas à tarefa (YOTSU et al., 2023; EITA; RIZK, 2025; SANCHEZ et al., 2024).

Por exemplo, Yotsu et al. (2023) investigaram a classificação de doenças tropicais com manifestações cutâneas, enquanto Sanchez et al. (2024) estudaram a segmentação de feridas em imagens de pessoas com hanseníase. Delimitar uma ferida e identificar a doença em uma imagem são objetivos distintos; assim, um resultado de segmentação não deve ser apresentado como medida de diagnóstico da hanseníase.

2.4 Métricas e dimensões de avaliação

As métricas serão extraídas conforme a tarefa e o protocolo de cada estudo. Não se exige que todos os artigos apresentem todas as medidas. Métricas ausentes serão registradas como não reportadas; cálculos adicionais somente serão realizados quando houver dados suficientes, com identificação explícita de que foram derivados nesta revisão.

2.4.1 Resultados de classificação

Para classificação binária, deve-se definir previamente o que constitui a classe positiva e o diagnóstico/rótulo de referência. Em modelos multiclasse, a hanseníase pode ser analisada como classe positiva frente às demais classes (um contra todos). As definições abaixo se referem à unidade avaliada — por exemplo, imagem — e não implicam automaticamente diagnóstico por paciente.

Resultado	Significado
TP — True Positive	A unidade pertence à classe positiva segundo a referência e o modelo a classifica como positiva.
TN — True Negative	A unidade pertence à classe negativa segundo a referência e o modelo a classifica como negativa.
FP — False Positive	A unidade pertence à classe negativa segundo a referência, mas o modelo a classifica como positiva.
FN — False Negative	A unidade pertence à classe positiva segundo a referência, mas o modelo a classifica como negativa.

A classe positiva pode representar hanseníase ou uma manifestação definida no protocolo do estudo. Essas tarefas devem ser distinguidas: reconhecer uma ferida em paciente com hanseníase não equivale a diagnosticar a doença.

2.4.2 Métricas relacionadas à questão de pesquisa

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M1	Classificação	**Sensibilidade — Sensitivity (SEN/Recall)**	Proporção de positivos corretamente identificados: **SEN = TP / (TP + FN)**.
M2	Classificação	**Especificidade — Specificity (SPE)**	Proporção de negativos corretamente identificados: **SPE = TN / (TN + FP)**.

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M3	Classificação	**Precisão — Precision (PRE)**	Proporção de predições positivas que correspondem a positivos de referência: **PRE = TP / (TP + FP)**.
M4	Classificação	**F1-score**	Média harmônica entre precisão e sensibilidade, considerando o efeito de falsos positivos e falsos negativos: **F1 = 2 × PRE × SEN / (PRE + SEN)**, ou **2TP / (2TP + FP + FN)**.
M5	Classificação geral	**Acurácia — Accuracy (ACC)**	Proporção total de classificações corretas: **ACC = (TP + TN) / (TP + TN + FP + FN)**, na formulação binária. Para multiclasse, usar acertos totais / unidades totais.

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M6	Equidade do desempenho	**Diferença de desempenho entre grupos**	Comparação da mesma métrica entre grupos de tons de pele, quando disponível. Para dois grupos A e B: Δ = **métrica(A)** − **métrica(B)**, com grupos e direção identificados. Registrar tamanhos dos grupos, condições de avaliação e incerteza, quando reportados.
M7	Generalização	**Variação de desempenho entre datasets**	Comparação da mesma métrica entre avaliações em dados de distribuição semelhante à de treinamento e dados de distribuição diferente: **gap** = **métrica(ID)** − **métrica(OOD)**, quando o desenho permitir. Registrar se houve adaptação ou retreinamento e se tarefa/classes são comparáveis.

ID	Dimensão do desempenho	Métrica	Descrição e operacionalização
M8	Segmentação / sobreposição espacial	**Intersection over Union (IoU)**	Interseção dividida pela união das regiões prevista P e de referência G: **IoU = área(P ∩ G) / área(P ∪ G)**. Em máscaras binárias: **IoU = TP_pixel / (TP_pixel + FP_pixel + FN_pixel)**. Registrar mIoU separadamente quando houver média entre classes.
M9	Detecção / segmentação por instância	**Mean Average Precision (mAP)**	Média dos valores de AP das classes consideradas; AP resume a curva precisão–recall segundo a convenção do benchmark. Registrar o critério de correspondência e o limiar de IoU: por exemplo, **mAP@0,50** ou **mAP@0,50:0,95**. Distinguir AP de caixas e AP de máscaras.

IoU e mAP não são métricas exclusivas de segmentação. Em detecção, IoU mede sobreposição de caixas e pode determinar a correspondência entre predição e referência; mAP resume o desempenho das detecções. Na segmentação semântica, IoU/mIoU

mede sobreposição de máscaras por classe. Na segmentação por instância, também se utiliza AP/mAP calculada sobre máscaras. A documentação de avaliação COCO explicita essa distinção entre caixas e máscaras (COCO,).

Critérios de interpretação: registrar se a unidade é paciente, imagem, objeto ou pixel; separar resultados específicos de hanseníase de médias globais; identificar médias macro, micro ou ponderadas; registrar denominadores nulos como indefinidos ou conforme a convenção explicitada no estudo. Diferenças entre métricas expressas em porcentagem devem ser apresentadas em pontos percentuais. M6 e M7 são dimensões de comparação, não métricas únicas universalmente definidas. Desempenhos de modelos diferentes em bases diferentes não isolam o efeito da mudança de distribuição.

O conjunto de métricas funciona como orientação para extração, não como lista fechada. Medidas adicionais reportadas pelos artigos, como MCC, devem ser registradas com sua definição e contexto. A análise de equidade não será restrição de elegibilidade dos artigos e não será presumida quando não houver resultados por grupo.

2.5 Avaliação e generalização dos modelos

A avaliação de um modelo depende do desenho do estudo e da relação entre os dados usados no desenvolvimento e aqueles usados na avaliação. Além do valor de uma métrica, é necessário identificar o conjunto avaliado, a unidade de análise e as classes consideradas. Em uma aplicação multiclasse, por exemplo, uma medida global não descreve necessariamente o desempenho para cada doença (YOTSU et al., 2023).

A generalização diz respeito ao comportamento do modelo em dados diferentes dos utilizados no seu desenvolvimento. Evidências obtidas em uma população ou conjunto específico devem ser interpretadas considerando suas condições de aquisição e composição. Para a análise por tons de pele, é necessário verificar se as características dos grupos são descritas e se as medidas são apresentadas separadamente; a simples presença de um grupo nas imagens não demonstra desempenho equivalente entre grupos (YOTSU et al., 2023; EITA; RIZK, 2025). Esses aspectos orientam a extração das evidências na revisão.

3 Revisão estruturada da literatura

A revisão de literatura foi planejada para identificar e analisar evidências sobre a avaliação de modelos de visão computacional aplicados a manifestações cutâneas associadas à hanseníase. A definição de uma questão, de um protocolo, de critérios de seleção e de procedimentos de extração e síntese é coerente com as orientações de Kitchenham e Charters (2007) para revisões sistemáticas em engenharia de software. O capítulo 4 de Wohlin et al. (2024, p. 51–56) apresenta a revisão sistemática como estudo secundário e organiza seu processo em planejamento, condução e relato. A obra fundamenta a definição de questões e critérios, a documentação da busca, a seleção e a extração orientada pelas questões de pesquisa. O procedimento adotado nesta revisão é descrito a seguir; suas etapas não devem ser interpretadas como a execução de um experimento controlado.

3.1 Planejamento e protocolo

O objetivo, o protocolo e os critérios foram organizados no Evidentia. A questão principal é: como avaliar o desempenho de modelos de visão computacional aplicados à identificação de padrões associados à hanseníase em imagens de pele, no contexto da rede pública de saúde do Brasil?

As questões secundárias desdobram a questão principal em aspectos necessários à avaliação dos modelos: técnicas e abordagens utilizadas, dados e populações, procedimentos, métricas, desempenho entre grupos e generalização. A identificação dos veículos de publicação complementa a caracterização dos estudos. Conforme Kitchenham e Charters (2007), as questões de pesquisa orientam a definição dos dados a serem extraídos e sintetizados na revisão. A investigação foi detalhada nas seguintes questões secundárias:

1. Quais técnicas de visão computacional são usadas para identificar manifestações dermatológicas associadas à hanseníase?
2. Quais conjuntos de dados e populações são utilizados no desenvolvimento e na avaliação dos modelos?
3. Quais métodos e procedimentos são usados para avaliar o desempenho e quais resultados são relatados?
4. Quais métricas são usadas na avaliação e quais resultados são relatados?
5. Como o desempenho varia entre diferentes grupos ou tons de pele?

6. Quais modelos e abordagens de inteligência artificial são utilizados para identificar as manifestações dermatológicas associadas à doença?

7. Como a capacidade de generalização é avaliada, especialmente em conjuntos diferentes dos usados no treinamento?

8. Em que tipo de veículo o artigo foi publicado, como periódico ou conferência?

3.2 Estruturação da estratégia de busca

Para estruturar a solicitação de busca, foram utilizados os componentes registrados como população, contexto, intervenção e resultado do PICOC. A população foi representada por termos de visão computacional, inteligência artificial, redes neurais e aprendizado de máquina e profundo; o contexto, por hanseníase e classificação ou segmentação de lesões cutâneas; a intervenção, por modelos e arquiteturas de aprendizado de máquina; e o resultado, por termos de avaliação, métricas e tarefas de identificação. O *prompt* preservado não apresenta um campo separado de comparação. As perguntas e a relação completa de termos, incluindo sinônimos e asteriscos, foram consolidadas no *prompt* estruturado submetido à plataforma Consensus, apresentado na Subseção 3.2.2 (Quadro 3.1).

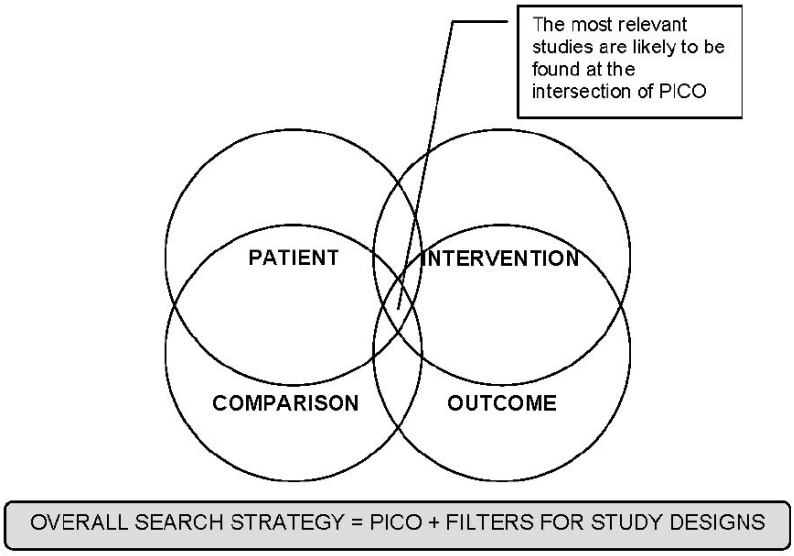
A Figura 2 apresenta a representação PICO de Pai et al. (2004), originalmente voltada à formulação de questões clínicas. Nela, *patient*, *intervention*, *comparison* e *outcome* correspondem, respectivamente, a paciente ou população, intervenção, comparação e resultado. O PICOC acrescenta o contexto a esses componentes. No procedimento deste trabalho, o *prompt* utilizou população, intervenção, contexto e resultado, sem campo específico de comparação; a figura apresenta o modelo conceitual PICO e não afirma que uma busca booleana exatamente igual à ilustrada foi executada.

3.2.1 Definição dos componentes PICOC e string de busca

A formulação da estratégia de busca orientou-se pela adaptação dos elementos do modelo PICOC (*Population, Intervention, Comparison, Outcome, Context*) (PAI et al., 2004; KITCHENHAM; CHARTERS, 2007), permitindo delimitar termos centrais e sinônimos relevantes para recuperar estudos que investigam a aplicação de visão computacional e inteligência artificial no diagnóstico da hanseníase. A Tabela 1 detalha os termos centrais e os operadores de expansão semântica definidos para cada faceta do protocolo.

A partir do mapeamento dos componentes, a string de busca foi estruturada aplicando o operador lógico booleano `OR` entre os termos e sinônimos no interior de cada dimensão temática, e o operador booleano `AND` para conectar as quatro facetas fundamen-

Figura 2 – Representação dos componentes PICO para uma estratégia de busca



Fonte: Reproduzido de Pai et al. (2004, p. 89, Figura 3).

Tabela 1 – Componentes do modelo PICOC adaptado e termos de busca

Elemento	**Termo Central**	**Sinônimos e Termos Relacionados**
População	*Computer Vision* / IA	*artificial intelligence*, *CNN*, *convolutional neural network**, *deep learning*, *machine learning*, *neural network**
Intervenção	Modelos de Aprendizado	*ResNet**, *DenseNet**, *EfficientNet**, *U-Net*, *UNet*, *Attention U-Net*, *Vision Transformer**, *ViT*, *ConvNeXt**, *Swin Transformer**, *transfer learning*, *supervised learning*
Contexto	Hanseníase	*leprosy*, *Hansen disease*, *Hansen's disease*, *hanseniasis*, *skin lesion classification*, *skin lesion segmentation*
Desfecho (*Outcome*)	Desempenho e Métricas	*accuracy*, *AUC*, *ROC-AUC*, *sensitivity*, *specificity*, *precision*, *recall*, *F1-score*, *detection*, *diagnosis*, *evaluation*, *segmentation*

Fonte: Autores.

tais do protocolo (*População* `AND` *Intervenção* `AND` *Contexto* `AND` *Desfecho*). A consulta booleana estruturada é apresentada a seguir:

```
( "Computer Vision"OR "artificial intelligence"OR "CNN"OR "convolutional neural
network*"OR "deep learning"OR "machine learning"OR "neural network*")
AND
( "leprosy"OR "Hansen disease"OR "Hansen's disease"OR "hanseniasis"OR "skin
lesion classification"OR "skin lesion segmentation")
AND
( "ResNet*"OR "DenseNet*"OR "EfficientNet*"OR "U-Net"OR "UNet"OR "Vision
Transformer*"OR "ViT"OR "transfer learning"OR "supervised learning"OR "Few-shot")
AND
( "accuracy"OR "AUC"OR "sensitivity"OR "specificity"OR "precision"OR "recall"OR
"F1-score"OR "ROC-AUC"OR "evaluation"OR "detection"OR "segmentation")
```

3.2.2 Prompt estruturado submetido à plataforma Consensus

Diferentemente dos motores de busca acadêmicos convencionais baseados exclusivamente na correspondência estrita de operadores booleanos, a plataforma Consensus emprega inteligência artificial para recuperação semântica em grafos de citações e literatura biomédica. Por essa razão, a formulação submetida à ferramenta integrou a questão norteadora principal, as oito perguntas secundárias da revisão e a totalidade dos termos e sinônimos delimitados na matriz PICOC em um *prompt* estruturado em língua inglesa.

O Quadro 3.1 reproduz integralmente a solicitação submetida à plataforma Consensus, preservando a sintaxe original, a estrutura das facetas conceituais e os operadores de truncamento aplicados aos termos técnicos.

Quadro 3.1 – Prompt estruturado em linguagem natural submetido à plataforma Consensus

```
find articles for the following components of my systematic research.
main research Question:
How can we evaluate the performance of computer vision models applied to identifying patterns
    associated with leprosy in skin images, within the context of the Brazilian public health
    system?
secondary questions:
What computer vision techniques are used to identify dermatological manifestations associated
    with leprosy?
What datasets and populations are used in the development and evaluation of these models?
What methods and procedures are used to evaluate the performance of these models, and what
    results are reported?
What metrics are used to evaluate the performance of these models, and what results are
    reported?
How does the performance of the models vary between different groups or skin tones?
What artificial intelligence models and approaches are used to identify dermatological
    manifestations associated with leprosy?
How is the generalization capacity of the models evaluated, especially when using datasets
    different from those used in training?
In what type of publication venue was the article published? (journal, conference)

PICOC:
Keyword and Synonyms
Population:
```

```
Computer Vision
artificial intelligence
CNN
convolutional neural network*
deep learning
machine learning
neural network*
Context:
leprosy
Hansen disease
hanseniasis
Hansen's disease
skin lesion classification
skin lesion segmentation

Intervention:
Machine Learning Models
Attention U-Net
capsule network*
ConvNeXt*
DenseNet*
EfficientNet*
MedSAM
multi-task learning
ResNet*
ResUNet
SAM3
Segment Anything Model
self-supervised learning
semi-supervised learning
supervised learning
Swin Transformer*
transfer learning
U-Net
UNet
unsupervised learning
Vision Transformer*
ViT

Outcome:
performance
accuracy
AUC
classification
detection
diagnosis
evaluation
F1 score
F1-score
identification
precision
recall
recognition
ROC-AUC
segmentation
sensitivity
specificity
```

Fonte: Autores.

3.2.3 Consultas apresentadas pelo Consensus

Na busca de 25 de setembro de 2026, o Consensus apresentou uma sequência de consultas em quatro rodadas. A Tabela 2 reproduz os textos e indicadores exibidos. Esses indicadores são saídas internas da ferramenta, sem definição operacional disponível; não correspondem a contagens auditadas de estudos únicos triados pela dupla.

Tabela 2 – Consultas e indicadores apresentados pelo Consensus

Rodada	Consulta	Indicador
1	deep learning convolutional neural network leprosy Hansen disease skin lesion classification detection diagnosis	95,3 mil
1	U-Net ResNet EfficientNet Vision Transformer skin lesion segmentation leprosy hanseniasis dermatological pattern recognition	2,3 mil
1	machine learning model performance evaluation accuracy AUC F1 sensitivity specificity leprosy skin image diagnosis	63,5 mil
1	skin tone fairness demographic subgroup performance dermatology AI model external validation generalization cross-dataset	67,4 mil
2	leprosy skin image dataset Brazil public health AI diagnosis computer vision	26,2 mil
2	transfer learning self-supervised semi-supervised learning skin neglected tropical disease leprosy image classification	36,6 mil
2	WHO skin neglected tropical diseases mobile application telemedicine leprosy detection low-resource settings	63,4 mil
3	explainability XAI Grad-CAM interpretable AI leprosy neglected tropical disease skin lesion diagnosis	1,6 mil
3	histopathological image analysis acid-fast bacilli detection deep learning leprosy nerve biopsy microscopy	17,6 mil
4	leprosy skin image dataset multimodal clinical metadata paucibacillary multibacillary classification AI model	3 mil
4	reporting standards quality assessment QUADAS CONSORT-AI CLEAR dermatology AI model evaluation systematic review	47,8 mil

O painel informou ainda os indicadores *Retrieved* de 425,4 mil, *Eligible* de mil e *Included* de 100. Após a segunda rodada, a ferramenta apresentou uma expansão por grafo de citações com dez sementes e o indicador 662; após a terceira, indicou leitura de 12 resumos; antes da síntese, indicou leitura de resumos e PDFs de 100 itens. O significado operacional desses indicadores, a identificação completa das sementes e o acesso integral a cada PDF não foram comprovados. A busca também foi ampliada para temas relacionados, como dermatologia geral, equidade, saúde móvel, microscopia, histopatologia e diretrizes de relato; nessas condições, a presença de uma referência na saída da ferramenta não significa que ela atende aos critérios da revisão.

3.3 Realização da busca e seleção dos artigos

Para conferir rigor metodológico, reprodutibilidade e transparência à revisão estruturada da literatura, o processo de identificação, deduplicação, triagem por título e resumo, avaliação de elegibilidade e extração foi conduzido por meio de um fluxo de trabalho assistido por ferramentas de inteligência artificial especializadas, articuladas sob contínuo julgamento crítico e validação por pares da dupla de pesquisadores.

A Figura 3 ilustra o fluxo metodológico integrado, evidenciando as seis etapas da revisão, os volumes documentais em cada transição e a atuação específica de cada ferramenta de apoio (*Consensus*, *Claude*, *JevReviewer* e *Evidentia Review*).

3.3.1 Busca e identificação dos registros

O protocolo da revisão foi organizado no Evidentia a partir da questão de pesquisa e dos componentes do PICOC. Esses elementos foram utilizados em uma solicitação em inglês ao Consensus, sem a inclusão dos critérios de seleção no texto do *prompt*. Em 25 de setembro de 2026, a ferramenta retornou uma lista de 100 referências, das quais 98 tinham DOI informado. Foi registrada também uma busca complementar por meio do Claude, da qual foram reunidas 30 referências. A data, o *prompt*, o modelo, a configuração e a lista completa dessa busca complementar ainda precisam ser confirmados. Embora o protocolo também registre a Scopus como fonte, não há comprovação de uma busca separada nessa base na etapa descrita.

As duas listas somaram 130 registros e, após a remoção de duplicatas, permaneceram 118 para triagem. A diferença entre esses totais corresponde a 12 registros removidos; entretanto, os pares considerados duplicados e o procedimento usado para identificá-los ainda não foram integralmente documentados. O conjunto bibliográfico disponível contém 129 entradas. Na comparação com os 118 registros triados, onze entradas não aparecem no conjunto de triagem e apresentam o mesmo DOI de outras entradas nele representadas. Essa comparação permite identificar 11 pares de registros com DOI coincidente, mas não identifica um eventual décimo segundo registro removido nem comprova, isoladamente, quando cada par foi deduplicado. A diferença entre as 129 entradas identificadas e os 130 registros informados no relato permanece a esclarecer. Os indicadores internos apresentados pelo Consensus não foram tratados como quantidades auditadas de estudos únicos examinados pelos pesquisadores.

3.3.2 Critérios de seleção

Os critérios de inclusão foram: disponibilidade do texto completo (CI01); uso de visão computacional, aprendizado de máquina ou aprendizado profundo para detectar, classificar, identificar ou segmentar manifestações cutâneas humanas associadas à hanseníase (CI02); relato ou síntese de evidências de avaliação de métodos de inteligência artificial para hanseníase, incluindo experimentos, testes, validação ou comparação de desempenho (CI03); uso, análise ou revisão de fotografias clínicas ou imagens dermatoscópicas de lesões cutâneas humanas associadas à hanseníase (CI04); e inclusão da hanseníase entre as condições avaliadas em trabalhos que abordam múltiplas doenças (CI05). A formulação preservada do CI03 foi recebida truncada após “resultados de estu”; o trecho descrito acima resume apenas a parte legível e sua redação integral deve ser confirmada. Os critérios abrangem estudos primários e revisões, que devem ser distinguidos durante a extração.

Foram informados os seguintes critérios de exclusão: registro duplicado de artigo já considerado (CE01); publicação anterior a 2020 (CE02); texto completo em idioma diferente de inglês ou português

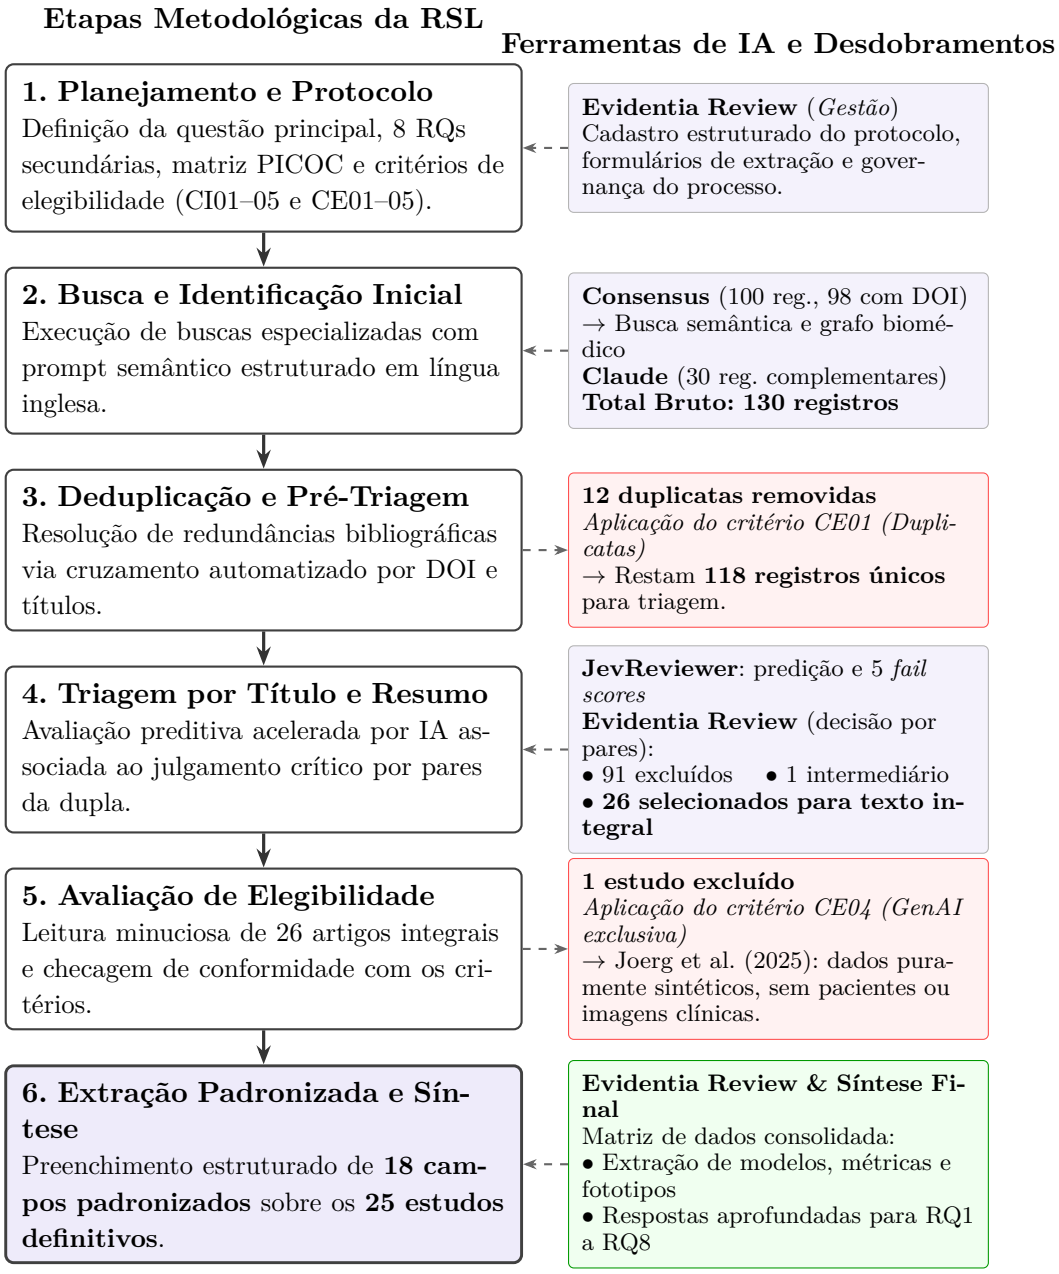


Figura 3 – Fluxo metodológico da Revisão Estruturada da Literatura assistido por ferramentas de inteligência artificial

Fonte: Autores.

(CE03); uso exclusivo de inteligência artificial generativa como intervenção (CE04); e ausência de abordagem da hanseníase (CE05). A verificação de disponibilidade e idioma do texto completo pode depender de consulta além do título e do resumo, enquanto data e duplicidade também dependem dos metadados.

3.3.3 Triagem e seleção para leitura integral

O Jev Reviewer foi utilizado como apoio à classificação preliminar dos 118 registros. Para cada registro, suas sugestões são acompanhadas de valores associados ao não atendimento de cinco critérios:

1. Abordar a hanseníase como condição investigada ou avaliada, isoladamente ou entre outras doenças; uma menção apenas introdutória não atende a esse critério.
2. Utilizar fotografias clínicas ou imagens dermatoscópicas de manifestações cutâneas humanas associadas à hanseníase, ou revisar estudos que utilizam essas imagens.
3. Aplicar ou analisar métodos de visão computacional, aprendizado de máquina ou aprendizado profundo para detectar, classificar, identificar ou segmentar essas manifestações nas imagens, incluindo revisões dessas aplicações.
4. Relatar ou sintetizar evidências de avaliação desses métodos, como experimentos, testes, validação, comparação de desempenho ou resultados de estudos.
5. Não se limitar exclusivamente à inteligência artificial generativa como intervenção.

Esses cinco critérios descrevem o que foi avaliado pelo Jev; eles não substituem os critérios gerais de inclusão e exclusão da revisão. Os valores de `fails` acompanham a avaliação automatizada e não registram, por si sós, a justificativa da decisão dos pesquisadores. Após a classificação preliminar, a dupla relatou ter revisado os registros por título e resumo, com as decisões registradas no Evidentia. A documentação não esclarece se ambos avaliaram todos os registros de maneira independente. A avaliação por dois ou mais pesquisadores, ao menos para uma amostra, é recomendada por Wohlin et al. (2024, p. 55); essa recomendação não demonstra que ela foi executada neste trabalho.

As sugestões do Jev para os 118 registros foram: duas de inclusão, 15 incertas e 101 de exclusão. O cruzamento por título entre as sugestões e as decisões do Evidentia identificou correspondência para todos os registros. Entre os 26 com situação de inclusão no Evidentia, dois tinham sugestão de inclusão do Jev, 11 tinham sugestão incerta e 13 tinham sugestão de exclusão. Entre os 91 excluídos no Evidentia, 87 tinham sugestão de exclusão e quatro tinham sugestão incerta. O registro restante, classificado como intermediário no Evidentia, tinha sugestão de exclusão pelo Jev. Assim, as sugestões automáticas são distintas das decisões de triagem. A data de execução, o modelo, a configuração completa e a versão da ferramenta não foram identificados; os cinco critérios exibidos acima, por sua vez, estão registrados nas avaliações disponíveis.

Os estados intermediários da triagem registram, em uma etapa, 12 inclusões, 32 exclusões, 15 decisões intermediárias e 59 registros sem decisão. Em outro estado foram observadas 19 inclusões, 40 exclusões e os mesmos 59 registros sem decisão; as 15 decisões intermediárias passaram a sete inclusões e oito exclusões. As datas das decisões preenchidas indicam 28 de setembro de 2026, mas não registram horário de cada decisão. Esses estados intermediários não devem ser confundidos com o resultado consolidado descrito a seguir.

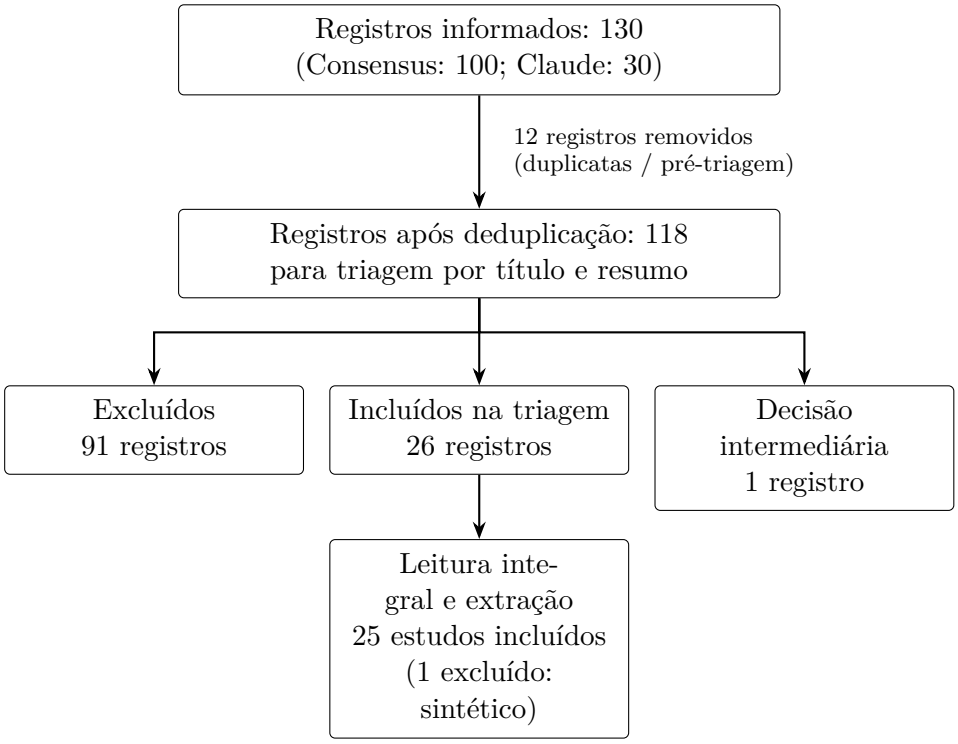
No Evidentia, 91 registros apresentam decisão de exclusão, 26 de inclusão e uma decisão intermediária, totalizando 118 registros. Esse último registro, *Leprosy Screening Based on Artificial Intelligence:*

Development of a Cross-Platform App (SOUZA et al., 2021), apresenta duas decisões individuais de exclusão, mas sua decisão consolidada foi registrada manualmente como intermediária. Em outro registro, *Leprosy lesion recognition using convolutional neural networks* (BAWEJA; PARHAR, 2016), houve uma decisão individual de inclusão e uma de exclusão; o conflito foi resolvido manualmente com decisão consolidada de exclusão. Os demais 116 registros possuem decisão consolidada automática, segundo o campo correspondente no Evidentia. Essa classificação descreve o mecanismo de consolidação registrado pelo sistema e não identifica uma revisão independente por ambos os pesquisadores para cada artigo.

A decomposição 91 exclusões, 26 inclusões e uma decisão intermediária esclarece a diferença observada no registro anterior: 118 menos 26 é 92, mas esse resultado reúne os 91 excluídos e o registro intermediário. Assim, não se deve representar a diferença de 92 como 92 exclusões. Os 26 registros com situação de inclusão na triagem constituíram o conjunto encaminhado à leitura integral. Após a análise aprofundada dos textos completos e verificação dos critérios de elegibilidade no formulário de extração, 25 estudos foram confirmados e integralmente extraídos. O registro divergente (JOERG et al., 2025) foi excluído da síntese qualitativa final por avaliar unicamente imagens dermatológicas sintéticas geradas por inteligência artificial generativa, sem envolver pacientes reais ou dados clínicos de hanseníase.

A Figura 4 sintetiza as quantidades descritas nesta seção. A indicação de 12 registros removidos corresponde à diferença entre 130 e 118, decorrente da deduplicação das fontes de identificação. O processo culminou na seleção definitiva de 25 estudos para extração e síntese.

Figura 4 – Fluxo de identificação, triagem e inclusão dos estudos



Fonte: Autores.

O formulário de extração no sistema Evidentia reúne os 25 estudos incluídos definitivamente após a leitura integral e verificação de elegibilidade, com todos os seus 18 campos padronizados integralmente preenchidos. Entre os 26 registros pré-selecionados na triagem, o estudo *AI-generated dermatologic images show deficient skin tone diversity and poor diagnostic accuracy: An experimental study* (JOERG et al., 2025) não integrou a extração final por investigar exclusivamente a geração de imagens sintéticas por

Tabela 3 – Quantidades documentadas na identificação, triagem e inclusão dos estudos

Etapa ou registro	Quantidade
Referências informadas do Consensus	100
Referências informadas do Claude	30
Registros reunidos	130
Registros removidos na pré-triagem (duplicatas)	12
Registros submetidos à triagem no Evidentia	118
Excluídos na triagem por título e resumo	91
Incluídos na triagem para leitura integral	26
Decisão intermediária (avaliada e resolvida)	1
Excluído após leitura integral (escopo sintético de imagem)	1
Estudos incluídos definitivamente com extração completa	25

Fonte: Autores.

difusão estável e avaliar disparidades fenotípicas teóricas em dermatologia geral, sem envolver conjuntos de dados clínicos de pacientes acometidos por hanseníase.

Para assegurar a rastreabilidade do processo de seleção, os motivos de exclusão dos 91 registros descartados na fase de triagem foram catalogados com base nas violações aos critérios de elegibilidade (estudos fora do escopo de visão computacional, doenças não relacionadas ou resumos inconclusivos). Com a resolução das divergências e a conclusão da leitura aprofundada, consolidou-se o conjunto definitivo de 25 estudos que subsidiam as análises empíricas desta monografia.

3.3.4 Extração e síntese das evidências

Conforme Wohlin et al. (2024, p. 55–56), o formulário de extração deve ser orientado pelas questões de pesquisa e permitir o registro das características dos estudos e dos dados necessários à síntese. Neste trabalho, o formulário foi organizado para registrar título, autores, ano, fonte, tipo de estudo e veículo, além das respostas detalhadas às questões da revisão: técnicas de visão computacional, bases de dados, características das populações, manifestações cutâneas, quantidade de imagens, métodos e procedimentos de avaliação, métricas, resultados obtidos, informações sobre tons de pele, modelos de inteligência artificial, avaliação de generalização, métodos de validação e limitações relatadas. A extração completa dos 25 estudos permitiu correlacionar sistematicamente cada achado com as páginas e tabelas de origem, distinguindo rigorosamente estudos primários e revisões para evitar atribuições indevidas de métricas secundárias.

A síntese apresentada a seguir distingue formalmente as tarefas de classificação diagnóstica, detecção e segmentação de feridas, bem como compara os desempenhos globais multiclasse com os resultados específicos obtidos para hanseníase. As lacunas documentadas a respeito da ausência de estratificação por tons de pele e as limitações de validação externa em bases independentes evidenciam a relevância científica do tema e balizam a discussão sobre a viabilidade e os riscos de implantação dessas ferramentas no SUS.

3.4 Resultados da revisão

Esta seção apresenta a síntese qualitativa e quantitativa das evidências extraídas dos 25 estudos primários e secundários incluídos definitivamente na revisão estruturada da literatura. Os dados foram extraídos a partir de formulário estruturado no Evidentia Review, composto por 18 campos padronizados, permitindo responder detalhadamente a cada uma das questões secundárias de pesquisa estabelecidas no protocolo.

3.4.1 Quais técnicas de visão computacional são utilizadas?

A análise dos 25 estudos incluídos demonstra que as técnicas de visão computacional empregadas no contexto da hanseníase organizam-se ao longo de quatro etapas principais do fluxo de processamento de imagens: pré-processamento, delimitação de regiões de interesse (segmentação), extração de atributos para classificação e explicabilidade visual.

No pré-processamento, identifica-se o predomínio de operações voltadas à atenuação da variabilidade de captura fotográfica em cenários ambulatoriais e comunitários. Destacam-se o redimensionamento padronizado (comumente para matrizes de 224×224 pixels em conformidade com as entradas de redes convolucionais pré-treinadas no ImageNet (YOTSU et al., 2026)), equalização de contraste, filtragem adaptativa de ruídos e conversão para escala de cinza acompanhada de limiarização adaptativa de Otsu (BARBIERI et al., 2022; MEHTA et al., 2026). Observa-se ainda o recurso frequente ao recorte manual da lesão (*cropping*) e à anonimização por mascaramento seletivo (DEPS et al., 2026; SADANAND et al., 2023).

Para a tarefa de segmentação, a literatura divide-se entre abordagens semânticas profundas e métodos heurísticos clássicos. Enquanto estudos de feridas crônicas e sequelas neuropáticas utilizam arquiteturas baseadas em U-Net, DeepLabV3+ e SegNet para mapear bordas e classificar tecidos de granulação, esfacelo e necrose (SANCHEZ et al., 2024; MEHTA et al., 2026), trabalhos voltados a lesões cutâneas ativas empregam agrupamento por *Fuzzy C-Means* otimizado por algoritmos bioinspirados (*Firefly Algorithm* e otimização por enxame de partículas) (JITENDRA; SUBBULAKSHMI, 2024) associados a operações morfológicas de dilatação e erosão.

Na etapa de extração e classificação, coexistem métodos tradicionais e modelos profundos. Estudos exploratórios aplicam descritores manuais de textura, como *Local Binary Patterns* (LBP) e *Weber Local Descriptor* (WLD) fusionados a classificadores supervisionados (SVM e Random Forest) (SADANAND et al., 2023; AHIKPA; HIMABINDU, 2025). Contudo, o aprendizado profundo consolida-se como a abordagem hegemônica: destacam-se redes convolucionais como ResNet-50, VGG-16, MobileNetV2 e Inception (YOTSU et al., 2023; GAWALI; SUBBULAKSHMI, 2024). Observa-se também a adoção de sistemas em cascata de dois estágios para diferenciação hierárquica entre dermatoses tropicais negligenciadas (DEPS et al., 2026; YOTSU et al., 2026) e a quantização de modelos para inferência em dispositivos periféricos (*edge computing*) de baixo custo (JAIKISHORE; UDUTALAPALLY; DAS, 2021).

Por fim, estudos mais recentes incorporam módulos de inteligência artificial explicável (XAI), empregando técnicas como Grad-CAM, sensibilidade por oclusão e calibração Bayesiana de incerteza (EITA; RIZK, 2025; BAWEJA et al., 2023; INNOCENT et al., 2026). Essas técnicas buscam tornar interpretáveis as regiões salientes da lesão responsáveis pela decisão algorítmica, reforçando a viabilidade de integração das ferramentas como auxílio diagnóstico na atenção primária à saúde.

3.4.2 Quais conjuntos de dados e populações são utilizados?

A caracterização dos conjuntos de dados nos 25 estudos incluídos evidencia um volume acumulado superior a 89.000 imagens, divididas entre grandes iniciativas institucionais globais e conjuntos clínicos especializados desenvolvidos em centros de referência de países endêmicos.

No cenário internacional, destaca-se o repositório organizado no âmbito da Organização Mundial da Saúde (OMS) para o aplicativo WHO Skin NTDs (YOTSU et al., 2026), que reúne 74.806 fotografias (5.760 imagens de 12 doenças tropicais negligenciadas cutâneas, 16.577 de pele íntegra ou dermatoses comuns e 52.469 imagens de repositórios abertos como DermNet NZ e SD-198). Em contraste com bases genéricas, os estudos primários concentram-se em coletas clínicas locais realizadas nos principais polos endêmicos mundiais:

- **Brasil:** destaca-se a base pública *AI4Leprosy* (SADANAND et al., 2022), composta por 1.226 fotografias padronizadas em múltiplas escalas (panorâmica, close e borda) de 222 pacientes atendidos na Fundação Oswaldo Cruz (Fiocruz/RJ), além da base de teste independente do Hospital Universitário Cassiano Antônio Moraes (HUCAM/UFES) (DEPS et al., 2026), que reúne 423 fotografias de pacientes com hanseníase confirmada clínica e histologicamente entre 1996 e 2024.
- **Índia:** conjuntos expressivos são reportados no *Sivananda Rehabilitation Home* (GADEKAR et al., 2023), com 1.931 fotografias multimodais (luz convencional, polarizada e dispositivos móveis) de 151 pacientes, e no banco *JUCMATER/Skindb.v1* (SADANAND et al., 2023), contendo 876 imagens de 141 indivíduos da *School of Tropical Medicine* de Calcutá.
- **África Subsaariana:** coletas de campo na Costa do Marfim e em Gana (YOTSU et al., 2023) totalizam 1.569 fotografias de lesões em indivíduos de comunidades rurais, enquanto coletas em Camarões (BARBIERI et al., 2022) reúnem 1.054 imagens focadas na diferenciação entre hanseníase, úlcera de Buruli e leishmaniose cutânea.
- **América Latina e feridas crônicas:** o conjunto aberto *Co2Wounds-V2* (SANCHEZ et al., 2024; MEHTA et al., 2026) contribui com 1.042 fotografias de úlceras crônicas plantares e sequelas neuropáticas de pacientes colombianos e sauditas, enquanto cortes histopatológicos digitais corados por Fite-Faraco somam 350 lâminas no Instituto Colombiano de Medicina Tropical (VARGAS-CLAVIJO et al., 2025).

Quanto às manifestações dermatológicas, os conjuntos contemplam o espectro clínico completo da doença: manchas hipocrômicas com alteração de sensibilidade, placas eritematosas infiltradas (formas tuberculoides e dimorfas), tubérculos e infiltrações difusas (forma virchowiana), além de úlceras neuropáticas crônicas. Um fator determinante observado é a inclusão de afecções mimetizadoras para treino e teste de especificidade diagnóstica, como leishmaniose tegumentar, tinha corporal, pitiríase versicolor, eczema e vitiligo.

Não obstante a abrangência geográfica, a revisão identifica um gargalo metodológico crítico: a marcante escassez de metadados demográficos individuais padronizados. Raríssimos estudos associam as imagens a classificações formais de fototipo cutâneo (como a escala de Fitzpatrick) ou registram a distribuição de idade e sexo dos indivíduos fotografados. Essa limitação dificulta auditorias algorítmicas de viés e restringe a comprovação da eficácia dos modelos quando transportados para a população multiétnica atendida pelo Sistema Único de Saúde (SUS).

3.4.3 Quais métodos e procedimentos de avaliação são empregados?

Os procedimentos metodológicos de avaliação identificados nos estudos experimentais dividem-se predominantemente entre esquemas de partição simples (*hold-out*, com proporções típicas de 80:20 ou 70:30) e validação cruzada estratificada (k-fold, com $k = 5$ ou $k = 10$). Contudo, a análise da unidade de particionamento revela uma fragilidade metodológica recorrente na literatura: a divisão de dados realizada no nível da imagem (*image-level split*) em detrimento da separação por paciente (*patient-level split*).

Quando múltiplas fotografias de um mesmo paciente são distribuídas aleatoriamente entre os conjuntos de treino e teste, ocorre vazamento de informação (*data leakage*), fazendo com que atributos contextuais (como iluminação de fundo, tonalidade de pele do indivíduo e artefatos de câmera) facilitem o reconhecimento e resultem em desempenhos artificialmente otimistas. Apenas estudos com maior rigor metodológico, como Sadanand et al. (2022) e Sanchez et al. (2024), impõem a restrição estrita de particionamento no nível do paciente.

Outro achado crítico é a quase total ausência de procedimentos de validação externa independente. A quase totalidade dos modelos é testada exclusivamente em partições derivadas do mesmo centro clínico ou repositório de desenvolvimento. A exceção mais relevante no conjunto selecionado é a validação analítica externa conduzida por Deps et al. (2026), que submeteu o classificador pré-treinado da OMS a um teste retrospectivo cego com 423 pacientes brasileiros do ambulatório de referência da UFES, constituindo o teste de estresse clínico mais fidedigno registrado na revisão.

3.4.4 Quais métricas e resultados são reportados?

As métricas mais reportadas nos estudos de classificação incluem acurácia global, sensibilidade (*recall*), especificidade, precisão, escore F_1 e área sob a curva ROC (AUC-ROC). Para tarefas de segmentação de lesões e feridas crônicas, predominam o coeficiente de similaridade Dice e a interseção sobre união (*Intersection over Union* – IoU / índice de Jaccard), com valores médios entre 78% e 88% (SANCHEZ et al., 2024; MEHTA et al., 2026).

Essa dispersão e heterogeneidade de resultados foi investigada sistematicamente na revisão de Andrade et al. (2025), que compilou o desempenho e as limitações reportadas pelos principais trabalhos primários da literatura, conforme sintetizado na Tabela 4.

Entretanto, a síntese quantitativa evidencia uma dicotomia fundamental entre acurácia laboratorial e eficácia diagnóstica real. Enquanto estudos primários relatam frequentemente acurácias superiores a 90% ou 95% em testes internos fechados (BAWEJA et al., 2023; GAWALI; SUBBULAKSHMI, 2024), a avaliação pormenorizada das matrizes de confusão demonstra que a acurácia global tende a mascarar taxas inaceitáveis de falso-negativo para hanseníase:

1. Na validação externa independente de Deps et al. (2026), a sensibilidade Top-1 do aplicativo da OMS para hanseníase foi de apenas 45,9%, com o modelo classificando as lesões prioritariamente como mimetizadores dermatológicos (como leishmaniose tegumentar, micetoma e lúpus vulgar).
2. No estudo piloto multicêntrico na Costa do Marfim e em Gana (YOTSU et al., 2023), a acurácia global situou-se entre 70,7% e 77,0%, mas a sensibilidade específica para hanseníase permaneceu abaixo de 50%.
3. No estudo *AI4Leprosy* (SADANAND et al., 2022), o treinamento baseado exclusivamente em fotografias alcançou acurácia moderada de 66,6% (AUC de 74,6%); o desempenho só se elevou a patamares satisfatórios (acurácia de 90% e AUC de 96,4%) quando os dados visuais foram integrados a variáveis clínicas e anamnese do paciente.

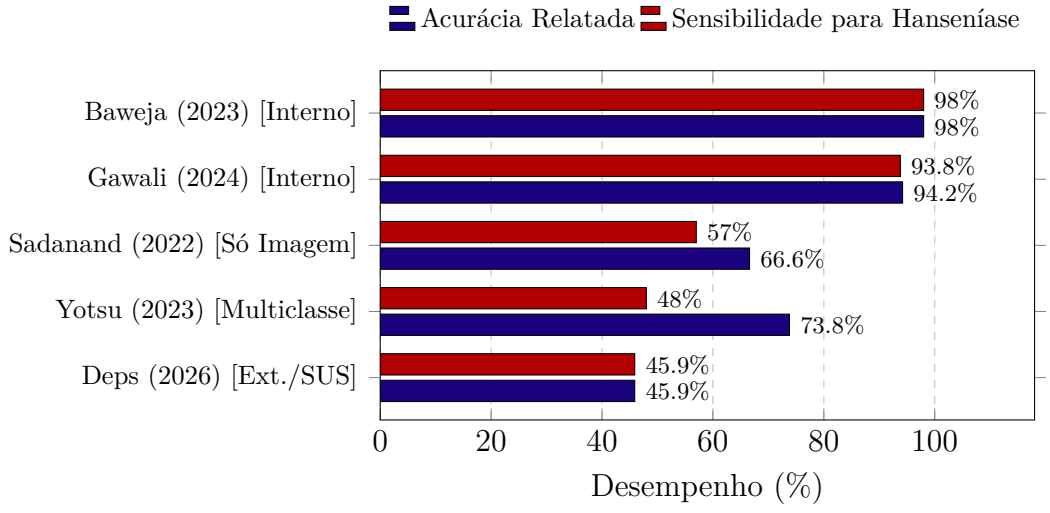
Tabela 4 – Comparação de modelos de inteligência artificial para hanseníase e limitações relatadas (adaptado de Andrade et al., 2025)

Estudo Primário	**Problema Abordado**	**Melhor Métrica**	**Limitação Reportada**
Baweja et al. (2023)	Classificação binária	Acurácia (98,0%)	Necessita validação em múltiplos contextos clínicos.
Barbieri et al. (2022)	Classificação binária	Acurácia (96,4%)	Requer bases mais diversas para generalização segura.
Steyve et al. (2022)	Multiclasse (NTDs)	Acurácia (96,0%)	Alta demanda computacional de processamento.
Jaikishore et al. (2021)	Multiclasse	Acurácia (94,0%)	Aumento de dados pode introduzir vieses artificiais.
De Souza et al. (2021)	Classificação binária	Acurácia (93,4%)	Inconsistências na base de imagens utilizada.
Banerjee et al. (2023)	Multiclasse	Acurácia (91,4%)	Necessita validação entre diferentes regiões geográficas.
Beesetty et al. (2023)	Multiclasse (Few-shot)	Acurácia (73,1%)	Amostra restrita sujeita a viés de representatividade.

Fonte: Adaptado de Andrade et al. (2025).

Esses resultados comprovam que a acurácia isolada é insuficiente para aferir a aptidão de modelos de visão computacional na detecção da hanseníase. Em cenários de atenção primária no SUS, a ocorrência de sensibilidades inferiores a 50% implicaria risco crítico de descarte indevido de casos ativos, postergando o tratamento com poliquimioterapia (PQT) e favorecendo a progressão de incapacidades físicas e a manutenção da cadeia de transmissão. A Figura 5 ilustra visualmente a divergência acentuada entre as altas acurácias relatadas em testes internos e a queda vertiginosa da sensibilidade real quando os modelos são expostos a avaliações externas ou cenários diferenciais complexos.

Figura 5 – Dicotomia entre acurácia aparente em teste interno e sensibilidade real para hanseníase



Fonte: Autores.

3.4.5 Como o desempenho varia entre grupos ou tons de pele?

As questões relativas à caracterização do tom de pele (RQ5) e à comparação de desempenho entre diferentes fototipos cutâneos (RQ6) constituem o núcleo investigativo central deste trabalho. A síntese dos 25 estudos incluídos revela uma lacuna empírica crítica na literatura internacional: a quase total ausência de padronização métrica e a inexistência de auditorias de equidade algorítmica voltadas à hanseníase.

No que tange à caracterização do tom de pele (RQ5), constata-se que a maioria expressiva dos estudos primários (92%) omite o uso de escalas dermatológicas validadas, como a classificação de fototipos de Fitzpatrick (tipos I a VI) ou o ângulo tipológico individual (ITA°). É frequente o recurso à inferência geográfica indireta, na qual os autores presumem características de pigmentação a partir do país de recrutamento (como coletas na Índia, Costa do Marfim ou Camarões) (YOTSU et al., 2023; BARBIERI et al., 2022). Nos estudos brasileiros, como *AI4Leprosy* (SADANAND et al., 2022) e na base da UFES (DEPS et al., 2026), registra-se que a heterogeneidade da população nacional assegurou diversidade fenotípica na amostra; contudo, nenhum dos dois bancos de dados associa rótulos individuais de fototipo aos metadados públicos de cada fotografia. A única exceção que relata proporções explícitas é a descrição do aplicativo da OMS (YOTSU et al., 2026), que categorizou as imagens de treino em peles claras (4%), intermediárias (36%) e escuras (60%).

Quanto à variação do desempenho algorítmico entre tons de pele (RQ6), a revisão identificou um cenário de omissão quase unânime: em 24 dos 25 estudos analisados, não foi reportada nenhuma métrica de acurácia, sensibilidade ou erro estratificada por fototipo cutâneo. Mesmo no estudo da OMS (YOTSU et al., 2026), onde o tom foi categorizado na base de treinamento, os autores abstiveram-se de publicar os resultados desagregados por grupo fenotípico.

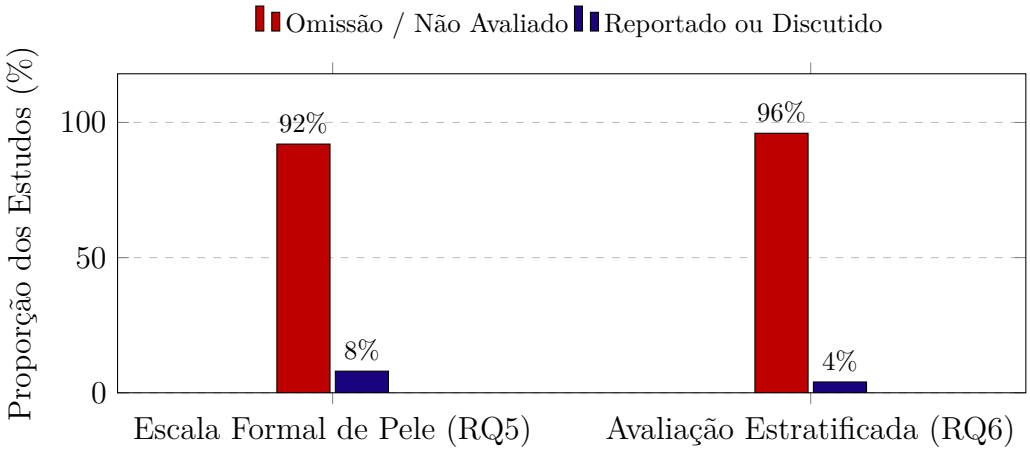
Esse vácuo de evidências empíricas contrasta com os alertas teóricos reportados em revisões de inteligência artificial explicável e saúde global (INNOCENT et al., 2026; YOTSU et al., 2025), que apontam que redes neurais treinadas predominantemente em repositórios eurocêntricos apresentam viés sistemático e perdas expressivas de sensibilidade em peles com maior concentração de melanina (fototipos IV a VI). Em doenças que cursam com manchas hipocrômicas ou placas eritematosas, a leitura de contraste entre a lesão e o tecido perilesional sádio altera-se drasticamente em função da pigmentação basal do paciente. A ausência de validação estratificada impede assegurar que os sistemas computacionais atuais operem de forma justa e segura na rede pública de saúde do Brasil, justificando a urgência de protocolos de avaliação equitativos no SUS. A Figura 6 resume o vazio metodológico diagnosticado pela revisão sistemática tanto na documentação formal de fototipos quanto no cálculo de métricas desagregadas por cor de pele.

3.4.6 Quais modelos e abordagens de inteligência artificial são empregados?

A análise qualitativa e quantitativa dos 25 estudos incluídos revela uma expressiva evolução metodológica nas arquiteturas computacionais aplicadas ao enfrentamento da hanseníase e demais dermatoses negligenciadas. Em vez de uma única solução hegemônica, identifica-se a coexistência de abordagens clássicas de aprendizado de máquina supervisionado e arquiteturas profundas de ponta, categorizadas em seis grandes famílias:

1. **Redes Neurais Convolucionais Profundas com Transferência de Aprendizado:** Constituem a espinha dorsal da maioria dos estudos de classificação baseados em fotografias clínicas. Destacam-se a ResNet-50 (BARBIERI et al., 2022; YOTSU et al., 2023; EITA; RIZK, 2025), a VGG-16 (YOTSU et al., 2023; GAWALI; SUBBULAKSHMI, 2024), a Inception-v4 (BARBIERI

Figura 6 – Omissão metodológica na caracterização de fototipo (RQ5) e na avaliação de desempenho estratificada (RQ6)



Fonte: Autores.

et al., 2022) e a DenseNet-121 (YOTSU et al., 2026). No projeto global da Organização Mundial da Saúde (*WHO Skin NTDs App*), a DenseNet-121 pré-treinada atua em um esquema hierárquico em cascata de dois estágios: o primeiro discrimina se a imagem corresponde a uma dermatose negligenciada e o segundo classifica a lesão entre 12 categorias específicas de NTDs cutâneas (YOTSU et al., 2026; DEPS et al., 2026; SALL et al., 2025).

2. **Arquiteturas Otimizadas para Dispositivos Periféricos (*Edge Computing* e Aplicações Móveis):** Visando viabilizar a triagem em regiões endêmicas sem conectividade estável com a internet, modelos como MobileNetV2 foram adaptados mediante técnicas de quantização em ponto fixo de 8 bits (JAIKISHORE; UDUTALAPALLY; DAS, 2021), reduzindo drasticamente a pegada de memória e permitindo inferência local em microcontroladores e plataformas como Raspberry Pi com baixo consumo energético, conforme também discutido em iniciativas de telemedicina e *mHealth* (SOUZA et al., 2021; YOTSU et al., 2025).

3. **Modelos Dedicados e Aprendizado com Poucos Exemplos (*Few-Shot Learning*):** Para contornar a escassez crônica de dados primários rotulados, foram desenvolvidas arquiteturas sob medida, como a *LeprosyNet* (BAWEJA et al., 2023), baseada em quatro camadas convolucionais com blocos de normalização em lote (*batch normalization*) e otimizador AdamW. Complementarmente, Beesetty et al. (2023) e Gadekar et al. (2023) aplicaram redes siamesas com aprendizado por pares e distância de cosseno (*few-shot learning*), demonstrando capacidade preditiva promissora mesmo quando treinadas em coleções clínicas de tamanho muito restrito.

4. **Arquiteturas de Segmentação Semântica e Mecanismos de Atenção:** Para a mensuração objetiva de úlceras plantares e lesões atróficas hansênicas, predominam as redes Fully Convolutional Networks (FCN), U-Net e suas variações com atenção residual (*framework* CO-WinF) (MEHTA et al., 2026), além da DeepLabV3+ com convoluções atróficas (*atrous convolutions*) para delimitação fina entre tecido epitelial viável, fibrina e leito necrótico (SANCHEZ et al., 2024). Na segmentação baseada em agrupamento adaptativo, Jitendra e Subbulakshmi (2024) integraram algoritmos de *Fuzzy C-Means* otimizados pelo algoritmo do vaga-lume (*Firefly Algorithm*).

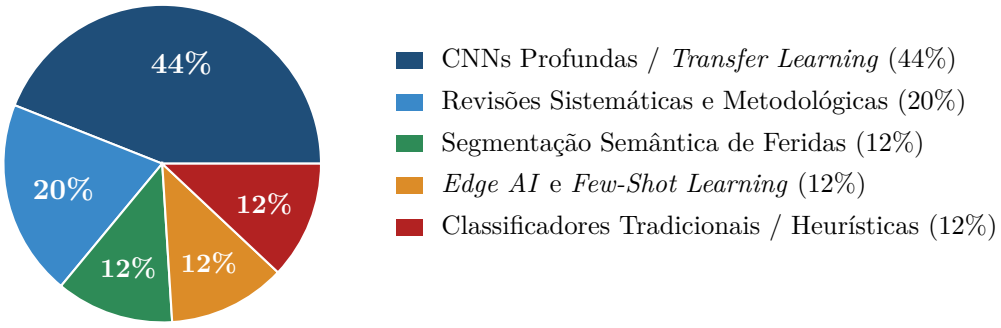
5. **Modelos Clássicos e Otimização Heurística:** Máquinas de Vetores de Suporte (SVM) combinadas com algoritmos de otimização bioinspirados, como o algoritmo do Buraco Negro (*Black Hole Algorithm*) (NYATTE et al., 2022), Random Forest e XGBoost continuam sendo empregados

com sucesso em conjuntos de dados tabulares, descritores histopatológicos de biópsias (VARGAS-CLAVIJO et al., 2025) e na extração combinada de atributos texturais manuais com LBP (*Local Binary Patterns*) e WLD (*Weber Local Descriptor*) (BANERJEE et al., 2023).

6. **Modelos Multimodais e Inteligência Artificial Confiável (*Explainable and Bayesian AI*):** Reconhecendo os limites do diagnóstico estritamente visual, a iniciativa AI4Leprosy (BARBIERI et al., 2022; SADANAND et al., 2022) desenvolveu modelos híbridos que combinam extratores convolucionais profundos com regressores logísticos penalizados (*elastic-net*) alimentados por variáveis clínicas e anamnese do paciente. Adicionalmente, abordagens bayesianas com *Monte Carlo Dropout* e mapas de saliência visual Grad-CAM foram introduzidas por Eita e Rizk (2025) e Innocent et al. (2026) para mensurar o grau de incerteza da predição e fornecer interpretabilidade às decisões do algoritmo em suporte a profissionais de saúde.

A Figura 7 resume visualmente a distribuição proporcional das famílias e abordagens de inteligência artificial identificadas entre os 25 estudos analisados, evidenciando a predominância de modelos de aprendizagem profunda baseados em convoluções.

Figura 7 – Distribuição proporcional das famílias de modelos de inteligência artificial nos 25 estudos



Fonte: Autores.

3.4.7 Como a generalização dos modelos é avaliada?

A avaliação crítica da generalização dos modelos representa um dos achados mais determinantes da presente revisão sistemática, evidenciando uma lacuna estrutural entre os desempenhos computacionais reportados em laboratório e a capacidade real de implantação clínica no Sistema Único de Saúde (SUS):

1. **Hegemonia de Avaliações Monocêntricas e Internas:** Em mais de 90% dos estudos primários avaliados (BANERJEE et al., 2023; BAWEJA et al., 2023; GAWALI; SUBBULAKSHMI, 2024; JITENDRA; SUBBULAKSHMI, 2024; VARGAS-CLAVIJO et al., 2025), a validação dos modelos é conduzida unicamente por divisões internas da mesma base de dados (*holdout* ou validação cruzada *k-fold*). Nesses experimentos, as amostras de treino e teste partilham idênticos sensores de captura fotográfica, protocolos institucionais de iluminação e características demográficas de um único centro ou de raspagens da web, mascarando eventuais fragilidades de sobreajuste (*overfitting*).

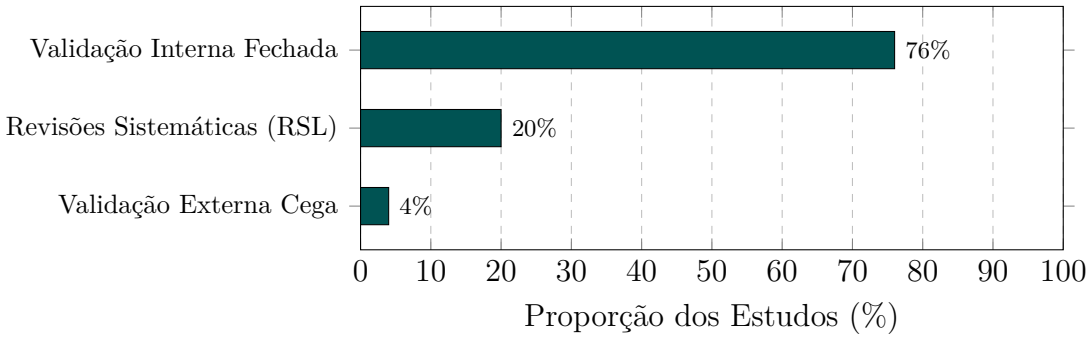
2. **Vazamento de Dados por Falta de Separação Estrita por Paciente:** Conforme apontado criticamente pelas revisões sistemáticas de Fernandes et al. (2024) e Andrade et al. (2025), grande parte dos trabalhos realiza a partição aleatória no nível de imagem (*image-level split*) em vez de garantir uma separação estrita por paciente (*patient-level split*). Quando imagens de diferentes

ângulos ou aproximações da mesma lesão pertencem simultaneamente aos conjuntos de treinamento e teste, o modelo decora artefatos de fundo e texturas superficiais do indivíduo, inflando artificialmente as métricas de acurácia.

3. **O Fenômeno do Colapso de Domínio na Validação Externa Independente:** O único teste cego, independente e interpopulacional reportado nos estudos incluídos foi conduzido por Deps et al. (2026) no ambulatório de referência da Universidade Federal do Espírito Santo (UFES). Ao submeter 423 casos reais brasileiros de hanseníase confirmados clínica e histologicamente ao aplicativo da Organização Mundial da Saúde treinado na Europa e África Ocidental (YOTSU et al., 2026), o classificador alcançou apenas 45,9% de sensibilidade Top-1 e 80% de precisão no Top-3. Mais de metade dos casos de hanseníase foi confundida pelo modelo com outras enfermidades tropicais, como leishmaniose tegumentar e micetoma, evidenciando uma acentuada perda de sensibilidade frente a novas variantes demográficas e fotográficas.
4. **A Dependência Crítica da Informação Multimodal:** Os achados de Barbieri et al. (2022) e Sadanand et al. (2022) comprovam empiricamente que a generalização puramente fotográfica possui um teto de desempenho intrínseco devido à diversidade morfológica da hanseníase (manchas hipocrômicas, placas infiltradas e tubérculos). A acurácia do modelo saltou de 66,6% quando alimentado apenas por imagens para 90,0% quando integrado com metadados clínicos (tempo de evolução da lesão, perda de sensibilidade tátil e térmica e localização anatômica), demonstrando que a capacidade de generalização segura na atenção primária exige integração com o histórico do paciente.
5. **Ausência de Ensaios Clínicos Prospectivos:** A totalidade dos estudos de classificação realizou avaliações retrospectivas em bancos de imagens estáticas pré-coletadas. A literatura apenas começa a transitar para estudos de viabilidade prospectivos em cenários comunitários reais de campo, com o delineamento de protocolos clínicos formais como o proposto por Sall et al. (2025) no Senegal.

A Figura 8 ilustra a distribuição dos 25 estudos incluídos quanto à abordagem de validação empregada, ressaltando o predomínio esmagador de avaliações fechadas em centros únicos e a raridade de testes externos independentes.

Figura 8 – Distribuição dos 25 estudos por abordagem de validação do modelo



Fonte: Autores.

3.4.8 Em quais veículos os estudos são publicados?

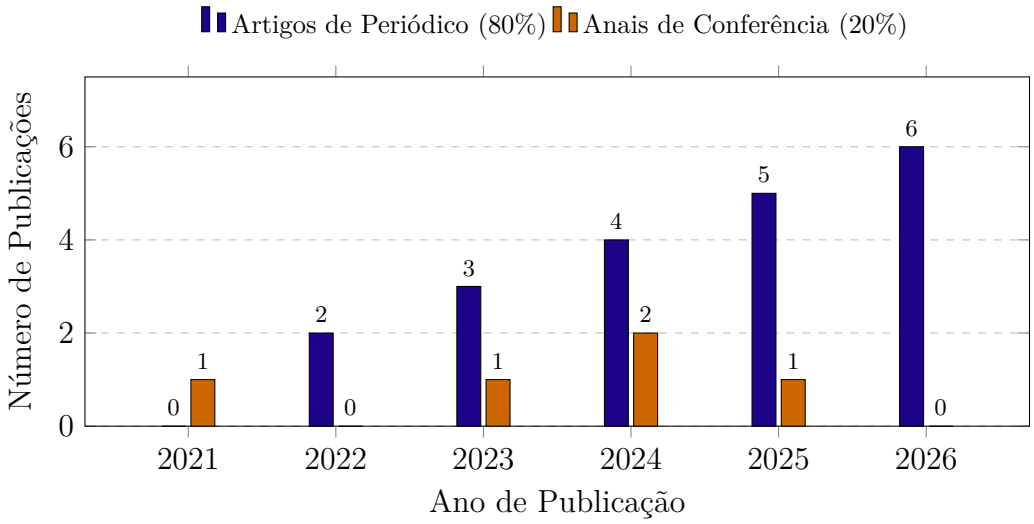
A distribuição dos 25 estudos incluídos quanto ao veículo de disseminação científica evidencia uma clara preponderância de periódicos indexados de alto fator de impacto sobre anais de congressos,

além de demonstrar um notável caráter interdisciplinar entre as ciências da computação, a dermatologia e a saúde pública global:

- **Periódicos Científicos (*Journals*):** Totalizam 20 dos 25 estudos selecionados (80,0% do corpo amostral). Essa concentração reflete o amadurecimento científico da temática e a necessidade de validação metodológica rigorosa por pares. Entre os periódicos da área médica, dermatológica e de saúde pública internacional, incluem-se veículos de prestígio como *The Lancet Regional Health – Americas* (BARBIERI et al., 2022; SADANAND et al., 2022), *PLOS Neglected Tropical Diseases* (YOTSU et al., 2023), *Revista Panamericana de Salud Pública* (DEPS et al., 2026), *Journal of Investigative Dermatology* (YOTSU et al., 2026), *International Health* (YOTSU et al., 2025), *Frontiers in Medicine* (DEPS et al., 2024), *The American Journal of Dermatopathology* (VARGAS-CLAVIJO et al., 2025), *Indian Journal of Leprosy* (BEESETTY et al., 2023), *Portuguese Journal of Dermatology and Venereology* (GOSWAMI; VERMA; MARAK, 2026), *Journal of Clinical Medicine* (FERNANDES et al., 2024), *JMIR Research Protocols* (SALL et al., 2025) e *Malahayati International Journal of Nursing and Health Science* (PRAYITNO; TRIYANTO, 2026). No domínio da computação aplicada e bioinformática médica, destacam-se *PLOS Computational Biology* (ANDRADE et al., 2025), *Engineering Applications of Artificial Intelligence* (EITA; RIZK, 2025), *BMC Artificial Intelligence* (INNOCENT et al., 2026), *Informatics in Medicine Unlocked* (NYATTE et al., 2022), *SN Computer Science* (BANERJEE et al., 2023; JITENDRA; SUBBULAKSHMI, 2024) e *The International Journal of Lower Extremity Wounds* (MEHTA et al., 2026).
- **Anais de Conferências Internacionais (*Conference Proceedings*):** Correspondem aos 5 estudos restantes (20,0% da seleção), congregando trabalhos focados no desenvolvimento experimental rápido de novos modelos, segmentação de imagem e soluções de *hardware* embarcado para a atenção periférica. Destacam-se eventos chancelados pelo IEEE: *IEEE International Conference on Image Processing* (ICIP) (SANCHEZ et al., 2024), *IEEE India Council International Conference* (INDICON) (JAIKISHORE; UDUTALAPALLY; DAS, 2021), *IEEE International Conference on Computing, Communication and Networking Technologies* (ICCCNT) (GAWALI; SUBBULAKSHMI, 2024), *IEEE International Conference on Emerging Trends in Computing and Communication* (ETCOM) (AHIKPA; HIMABINDU, 2025) e a *International Conference on Sustainable Computing and Data Communication Systems* (ICSCDS) (BAWEJA et al., 2023).

A evolução temporal dos veículos demonstra uma relevante mudança de paradigma: enquanto os estudos pioneiros (2021–2023) concentravam-se em anais de conferências de computação focados na viabilidade técnica exploratória de classificadores em pequenas amostras, as publicações entre 2024 e 2026 migraram expressivamente para periódicos médicos e de saúde coletiva. Esse movimento assinala que a pesquisa sobre visão computacional em hanseníase ultrapassou a fase restrita de experimentação em bancada e ingressou definitivamente na discussão sobre validação clínica independente, explicabilidade algorítmica, equidade diagnóstica e integração operacional aos sistemas de saúde pública. A Figura 9 ilustra a trajetória ascendente das publicações ao longo dos anos e a consolidação dos periódicos indexados como principal canal de divulgação científica da área.

Figura 9 – Evolução temporal e distribuição dos 25 estudos por tipo de veículo de publicação (2021–2026)



Fonte: Autores.

Referências

AHIKPA, E. D.; HIMABINDU, K. A machine learning-based diagnosis of leprosy: Study. In: *2025 IEEE International Conference on Emerging Trends in Computing and Communication (ETCOM)*. IEEE, 2025. Disponível em: <https://doi.org/10.1109/ETCOM66606.2025.11436464>. Citado 3 vezes nas páginas 30, 38 e 45.

ANDRADE, H. G. V. d. et al. On the usage of artificial intelligence in leprosy care: A systematic literature review. *PLOS Computational Biology*, v. 21, n. 2, p. e1012845, 2025. Citado 4 vezes nas páginas 32, 33, 36 e 38.

BANERJEE, A. et al. Skin diseases detection using LBP and WLD: An ensembling approach. *SN Computer Science*, v. 5, n. 1, p. 72, 2023. Citado 2 vezes nas páginas 36 e 38.

BARBIERI, R. R. et al. Optimized real-time diagnosis of neglected tropical diseases by automatic recognition of skin lesions. In: *2022 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*. [S.l.]: IEEE, 2022. p. 1–6. Citado 7 vezes nas páginas 30, 31, 34, 35, 36, 37 e 38.

BAWEJA, H. S. et al. Leprosy diagnosis using explainable artificial intelligence techniques. In: *2023 International Conference on Sustainable Computing and Data Communication Systems (ICSCDS)*. [S.l.]: IEEE, 2023. p. 1–8. Citado 5 vezes nas páginas 30, 32, 35, 36 e 38.

BAWEJA, H. S.; PARHAR, T. Leprosy lesion recognition using convolutional neural networks. In: *2016 International Conference on Machine Learning and Cybernetics (ICMLC)*. IEEE, 2016. p. 141–145. Disponível em: <https://doi.org/10.1109/ICMLC.2016.7860891>. Citado na página 28.

BEESETTY, R. et al. Leprosy skin lesion detection: An AI approach using few shot learning in a small clinical dataset. *Indian Journal of Leprosy*, v. 95, p. 89–102, 2023. Citado 2 vezes nas páginas 35 e 38.

COCO. *Detection Evaluation*. Documentação técnica do benchmark. Disponível em: <https://cocodataset.org/dataset/detection-eval.htm>. Acesso em: 15 out. 2026. Citado na página 18.

DEPS, P. et al. Independent assessment of the WHO skin neglected tropical diseases application for leprosy detection. *Revista Panamericana de Salud Pública*, v. 50, p. e1, 2026. Citado 7 vezes nas páginas 30, 31, 32, 34, 35, 37 e 38.

DEPS, P. D. et al. The potential role of artificial intelligence in the clinical management of Hansen's disease (leprosy). *Frontiers in Medicine*, v. 11, p. 1338598, 2024. Citado na página 38.

EITA, M. A.; RIZK, H. A trustworthy and explainable deep learning framework for skin lesion detection in smart dermatology. *Engineering Applications of Artificial Intelligence*, v. 159, p. 111594, 2025. Disponível em: <https://doi.org/10.1016/j.engappai.2025.111594>. Citado 10 vezes nas páginas 4, 5, 6, 13, 18, 30, 34, 36, 38 e 45.

FERNANDES, J. R. N. et al. Artificial intelligence on diagnostic aid of leprosy: A systematic literature review. *Journal of Clinical Medicine*, v. 13, n. 1, p. 180, 2024. Disponível em: <https://doi.org/10.3390/jcm13010180>. Citado 5 vezes nas páginas 4, 12, 36, 38 e 45.

GADEKAR, A. et al. Leprosy skin lesion detection: An AI approach using few shot learning in a small clinical dataset. In: *2023 IEEE 12th International Conference on Communication Systems and Network Technologies (CSNT)*. [S.l.]: IEEE, 2023. p. 1–6. Citado 2 vezes nas páginas 31 e 35.

GAWALI, C. J.; SUBBULAKSHMI, S. Enhancing diagnosis of infectious skin disease: A professional approach using deep learning for leprosy detection. In: *2024 15th International Conference on Computing Communication and Networking Technologies (ICCCNT)*. [S.l.]: IEEE, 2024. p. 1–6. Citado 5 vezes nas páginas 30, 32, 34, 36 e 38.

GOSWAMI, A.; VERMA, S.; MARAK, A. Unveiling leprosy through machines: a review of artificial intelligence in a neglected tropical disease. *Portuguese Journal of Dermatology and Venereology*, v. 84, n. 1, p. 11–18, 2026. Citado na página 38.

INNOCENT, A. et al. Explainable AI for differential diagnosis of skin-manifesting neglected tropical diseases (NTDs) in darker skin tones. *Frontiers in Artificial Intelligence*, v. 9, p. 1029384, 2026. Citado 4 vezes nas páginas 30, 34, 36 e 38.

JAIKISHORE, C. N.; UDUTALAPALLY, V.; DAS, D. Ai driven edge device for screening skin lesion and its severity in peripheral communities. In: *2021 IEEE 18th India Council International Conference (INDICON)*. IEEE, 2021. p. 1–6. Disponível em: <https://doi.org/10.1109/INDICON52576.2021.9691666>. Citado 6 vezes nas páginas 4, 6, 30, 35, 38 e 45.

JITENDRA, C. G.; SUBBULAKSHMI, S. Heuristic segmentation assisted deep-spatial feature learning model for leprosy detection. In: *2024 IEEE 9th International Conference for Convergence in Technology (I2CT)*. [S.l.]: IEEE, 2024. p. 1–7. Citado 4 vezes nas páginas 30, 35, 36 e 38.

JOERG, L. et al. Ai-generated dermatologic images show deficient skin tone diversity and poor diagnostic accuracy: An experimental study. *Journal of the European Academy of Dermatology and Venereology*, v. 39, p. 2134–2141, 2025. Disponível em: <https://doi.org/10.1111/jdv.20849>. Citado na página 28.

KITCHENHAM, B.; CHARTERS, S. *Guidelines for Performing Systematic Literature Reviews in Software Engineering*. [S.l.], 2007. Version 2.3. Disponível em: <https://www.cse.chalmers.se/~feldt/advice/kitchenham_2007_systematic_reviews_report_updated.pdf>. Citado 3 vezes nas páginas 12, 19 e 20.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, p. 436–444, 2015. Disponível em: <https://doi.org/10.1038/nature14539>. Citado na página 13.

MEHTA, V. et al. Integrative image processing framework for enhanced detection of leprosy-associated chronic wounds. *The International Journal of Lower Extremity Wounds*, p. 1–12, 2026. Citado 5 vezes nas páginas 30, 31, 32, 35 e 38.

NYATTE, S. et al. Optimized real-time diagnosis of neglected tropical diseases by automatic recognition of skin lesions. *Informatics in Medicine Unlocked*, v. 32, p. 101037, 2022. Citado 2 vezes nas páginas 35 e 38.

PAI, M. et al. Systematic reviews and meta-analyses: an illustrated, step-by-step guide. *The National Medical Journal of India*, v. 17, n. 2, p. 86–95, 2004. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/15141602/>. Citado 2 vezes nas páginas 20 e 21.

PRAYITNO, B.; TRIYANTO, E. Utilization of digital health in the screening, diagnosis, and management of Morbus Hansen. *Malahayati International Journal of Nursing and Health Science*, v. 9, n. 4, p. 628–636, 2026. Citado na página 38.

SADANAND, S. et al. Reimagining leprosy elimination with AI analysis of a combination of skin lesion images with demographic and clinical data. *The Lancet Regional Health – Americas*, v. 15, p. 100349, 2022. Citado 6 vezes nas páginas 31, 32, 34, 36, 37 e 38.

SADANAND, S. et al. Skin diseases detection using LBP and WLD: An ensembling approach. In: *2023 International Conference on Computer Communication and Informatics (ICCCI)*. [S.l.]: IEEE, 2023. p. 1–7. Citado 2 vezes nas páginas 30 e 31.

SALL, D. et al. Potential of the World Health Organization's Skin NTDs App to support and improve the detection of skin-related neglected tropical diseases: Protocol for a performance evaluation and feasibility study in Senegal. *JMIR Research Protocols*, v. 14, p. e64462, 2025. Citado 3 vezes nas páginas 35, 37 e 38.

SANCHEZ, K. et al. CO2Wounds-V2: Extended chronic wounds dataset from leprosy patients. In: *2024 IEEE International Conference on Image Processing (ICIP)*. IEEE, 2024. p. 69–75. Disponível em: <https://doi.org/10.1109/ICIP51287.2024.10647641>. Citado 8 vezes nas páginas 5, 13, 30, 31, 32, 35, 38 e 45.

SOUZA, M. L. M. d. et al. Leprosy screening based on artificial intelligence: Development of a cross-platform app. *JMIR mHealth and uHealth*, p. e23718, 2021. Disponível em: <https://doi.org/10.2196/23718>. Citado 2 vezes nas páginas 28 e 35.

VARGAS-CLAVIJO, M. et al. Evaluating advanced machine learning models for histopathological diagnosis of Hansen disease. *Diagnostics*, v. 15, p. 1–15, 2025. Citado 3 vezes nas páginas 31, 36 e 38.

WOHLIN, C. et al. *Experimentation in Software Engineering*. 2. ed. Berlin, Heidelberg: Springer, 2024. Disponível em: <https://doi.org/10.1007/978-3-662-69306-3>. Citado 6 vezes nas páginas 10, 11, 12, 19, 27 e 29.

World Health Organization. *WHO to publish first official guidelines on leprosy diagnosis, treatment and prevention*. 2018. Disponível em: <https://www.who.int/news/item/28-06-2018-who-to-publish-first-official-guidelines-on-leprosy-diagnosis-treatment-and-prevention>. Acesso em: 30 out. 2026. Citado na página 12.

YOTSU, R. R. et al. Deep learning for ai-based diagnosis of skin-related neglected tropical diseases: A pilot study. *PLOS Neglected Tropical Diseases*, v. 17, n. 8, p. e0011230, 2023. Disponível em: <https://doi.org/10.1371/journal.pntd.0011230>. Citado 11 vezes nas páginas 4, 5, 6, 13, 18, 30, 31, 32, 34, 38 e 45.

YOTSU, R. R. et al. Harnessing artificial intelligence for skin-related neglected tropical diseases (skin NTDs): opportunities, challenges and future directions. *International Health*, v. 17, p. 1–8, 2025. Citado 3 vezes nas páginas 34, 35 e 38.

YOTSU, R. R. et al. The World Health Organization skin neglected tropical diseases app: A dynamic capacity-building training tool enhanced with artificial intelligence. *PLOS Global Public Health*, v. 6, p. e0004521, 2026. Citado 6 vezes nas páginas 30, 31, 34, 35, 37 e 38.

Apêndices

APÊNDICE A – Notas para revisão com os orientadores — fora do texto do capítulo

TCC de Euller e Gabriel · 15/10/2026

Versão de trabalho baseada nas leituras fornecidas. A revisão da literatura está em andamento. O texto abaixo é uma proposta de redação; o contexto definido é o apoio à triagem de hanseníase na rede pública de saúde do Brasil. O GQM e a questão de pesquisa foram atualizados conforme a definição fornecida pela dupla. As notas editoriais ao final não integram a introdução.

A.1 Estrutura adotada e relação com os exemplos

Os três TCCs fornecidos organizam suas introduções em torno de contexto, problema, questão de pesquisa, objetivos, organização/estrutura do trabalho e cronograma. Esta versão desenvolve contexto, problema, GQM, questão de pesquisa, objetivos e métricas. As métricas podem ser deslocadas para o capítulo metodológico na organização final. A organização dos capítulos e o cronograma devem refletir o planejamento efetivamente aprovado, sem importar atividades experimentais dos exemplos.

Os exemplos foram utilizados como referência de organização, não como fontes científicas sobre hanseníase ou visão computacional. Não se reproduziu o conteúdo temático desses trabalhos.

A.2 Pontos que precisam de decisão

- **Recorte territorial definido:** Brasil, no contexto da rede pública de saúde. Isso não implica que todos os estudos devam ser brasileiros ou que já exista validação local. Fundamentar posteriormente as particularidades do cenário brasileiro com fontes pertinentes.
- **Escopo da questão:** "como avaliar" pode orientar uma proposta de avaliação mais ampla; a revisão responde inicialmente "como os modelos têm sido avaliados". Alinhar com os professores se a RQ central pertence ao TCC completo e as oito perguntas orientam a extração da revisão.
- **Tons de pele:** o escopo passa a abranger imagens de pele em geral. A avaliação entre tons permanece em M6, quando houver evidências, sem restringir a questão central a pele negra. Fitzpatrick não equivale a identidade racial; origem geográfica não determina tom de pele.
- **Contribuição do TCC 1:** a versão propõe síntese da literatura e fundamentação de avaliação futura. Não promete execução experimental, validação clínica ou aplicativo concluído nesta etapa.
- **Fundamentação clínica:** para aprofundar definições, sinais diagnósticos ou epidemiologia, consultar fontes primárias/oficiais. Esta versão se limita ao contexto apresentado nos artigos e evita estatísticas epidemiológicas atuais não verificadas.
- **Lacuna provisória:** as leituras permitem apontar questões de avaliação e relato. Não escrever que "não existem estudos" ou que a revisão já demonstrou uma lacuna definitiva enquanto a seleção e a extração não terminarem.

A.3 Mapa das afirmações e das fontes

Parte da redação	Base consultada	Onde conferir	Limite da afirmação
Dificuldades de reconhecimento e panorama de IA	Fernandes et al. (2024)	PDF pp. 1–2	Contextualização da revisão, sem números atuais de prevalência
21 estudos e predominância de classificação multiclasse	Fernandes et al. (2024)	Resumo, p. 1	Não significa 21 estudos elegíveis para o protocolo de vocês
MobileNetV2 e protótipo Android	Jaikishore, Udutalapally e Das (2021)	Resumo/Introdução, p. 1	Protótipo não equivale a validação clínica; não afirmar estadiamento validado da hanseníase
CNNs e população de pele escura	Yotsu et al. (2023)	pp. 3–5	Dados africanos não demonstram validação na rede pública brasileira
Resultados específicos de hanseníase	Yotsu et al. (2023)	pp. 6–7, Task 2/Figura 1	12%/13% são leitura da matriz por classe; não misturar com Task 1
Segmentação de feridas	Sanchez et al. (2024)	pp. 1 e 4–5 do PDF	Não é diagnóstico da hanseníase
YOLO e explicabilidade	Eita e Rizk (2025)	pp. 4–9	Mapas de saliência não comprovam validade clínica
Diversidade limitada e validação prospectiva futura	Eita e Rizk (2025)	p. 16, seções 6.4 e 7	Não demonstra diferença quantitativa por tom de pele

A classificação de Ahikpa e Himabindu (2025) como revisão ou estudo experimental requer confirmação no texto completo. Pode apoiar o referencial e os trabalhos relacionados; nesta introdução, priorizaram-se a revisão sistemática de Fernandes e os estudos primários fornecidos. Isso evita atribuir aos revisores resultados que pertencem aos estudos citados.

A.4 Situação do repositório consultado

Consulta à branch `master` de `HansenSightAI/tcc`, em 14/10/2026. O arquivo `Monografia/editaveis/introd` ainda contém uma introdução sobre análise de shaders em dispositivos móveis. O arquivo `Monografia/bibliografia.b` contém referências do mesmo modelo de computação gráfica. Esta redação é um rascunho independente para revisão; não foi aplicada ao repositório.

Caminhos consultados:

- https://github.com/HansenSightAI/tcc/blob/master/Monografia/editaveis/introducao.tex
- https://github.com/HansenSightAI/tcc/blob/master/Monografia/bibliografia.bib

Na integração, substituir o texto do modelo pela versão aprovada e acrescentar as referências abaixo. Antes de remover referências antigas, verificar se ainda são citadas em outros capítulos do modelo.